

## TEORIE ML 2

### SĂPTĂMÂNA 3

- [ $y \neq h_t(x)$ ]  $\leftrightarrow$
- $\rightarrow E_t = \sum_{x \in D} p_{x,y} = \sum_{x \in D}$  (distribuție în  
 care ponderă la antrenare (calculă  
 calcul probabilitățile instanțelor clasificate  
 corect, sau nu. Iar);  
 $E_t = \frac{1}{2} \sum_{x \in D} p_{x,y} + p_{x,h_t(x)}$  și dacă  $E_t = 0$  sunt  
 AdaBoost se oprește și ipoteza  $h_t(x)$ ;  
 $\rightarrow$  la fiecare iteratie, obținem o nouă buclă  
 ipoteză slabă (care are resurse ponderate  
 la antrenare minima);  
 $\rightarrow E_t = \frac{1}{2} - \delta_t$ ;  
 $\rightarrow S = \{(x_1, y_1), \dots, (x_m, y_m)\}$  este setul de  
 date de antrenament,  $x_i \in \mathbb{R}^n$ ,  $y_i \in \{-1, +1\}$ ;  
 $\rightarrow h: x \rightarrow \{-1, +1\} \Leftrightarrow$  ipoteză;  $T$  este nr. de  
 iteratii;  
 $\rightarrow D_t(i) = \frac{1}{m}, \forall i = 1, m$ ;  
 $\rightarrow$  la fiecare iteratie  $t$  ( $t=1, T$ ), producem  
 ipoteza  $h_t$  cu resurse ponderate la  
 antrenare  $E_t$ , facem update la distribuție,  
 $D_{t+1}(i) = \frac{1}{\delta_t} D_t(i) \cdot e^{-y_i h_t(x_i)}, \forall i = 1, m$   
 $(\text{unde } \delta_t \text{ este un normalizator})$ . Ponder  
 care unei probabilități să fie  $e^{-\delta_t y_i h_t(x_i)}$  este  
 $e^{-\delta_t}$ , dacă  $y_i = h_t(x_i)$  și  $e^{\delta_t}$ , altfel și

$$\hat{d}_t = \frac{1}{n} \ln \frac{1 - \hat{e}_t}{\hat{e}_t},$$

→ în următorul calculăm  $\hat{H}_T = \text{sign} \left( \sum_{t=1}^T \hat{d}_t \hat{h}_t \right)$

- totul majoritar;
- normalizator  $\Leftrightarrow$  factor de normalizare;
- AdaBoost poate produce rezultate diferențiale atunci când are posibilitatea să alegă între 2 sau mai multe (cel mai bun) ipoteze posibile;

→  $\text{err } D_{t+1}(\hat{h}_t) = \frac{1}{2} \Rightarrow$  ipoteza  $\hat{h}_t$  nu poate fi selectată și la iteratie  $t+1$  (nu este bine).

și selectată la o iteratie ulterioară;

$$\hat{d}_t = e^{-\hat{d}_t} \cdot \frac{(1 - \hat{e}_t)}{\hat{e}_t} + \hat{e}_t \cdot \hat{e}_t \Rightarrow$$

$$\hat{d}_t = 2\sqrt{\hat{e}_t(1 - \hat{e}_t)} \quad (0 < \hat{d}_t < 1);$$

$$D_{t+1}(i) = \begin{cases} \frac{D_t(i)}{2\hat{e}_t}, & i \in M = \{i | y_i \neq \hat{h}_t(x_i)\}; \\ \frac{D_t(i)}{2(1 - \hat{e}_t)}, & i \in C = \{i | y_i = \hat{h}_t(x_i)\}. \end{cases}$$

→  $e_i > e_j \Rightarrow d_i < d_j$  (antimonotonie);

→  $e_i > e_j \Rightarrow d_i < d_j$  (antimonotonie);

$$\text{err } D_{t+1}(\hat{h}_t) = \frac{1}{2} \cdot \hat{d}_t \cdot \hat{e}_t, \text{ unde}$$

$$\text{err } D_{t+1}(\hat{h}_t) = \sum_{i=1}^n D_{t+1}(x_i | \hat{h}_t(x_i) \neq y_i);$$

$$\text{err } D_{t+1}(\hat{h}_t) = \frac{1}{2};$$

(2)

- $\rightarrow \sum_{i \in M} d_t(i) = \epsilon_t$ ,  $M = \{i \mid y_i \neq f_t(x_i)\}$ ;  
 atunci cănd lucram cu AdaBoost, este tot  
 nevoie să tinem cont și de  
 compagii externe (clasifică toate instanțele  
 cu același ~~număr~~);  
 ↳ slides DT, de la slide-ul 10+;  
 ↳ condiții de învățabilitate și stabilitate (condiții de  
 convergență);  
 $d_{t+1}(i) = \frac{\pi}{\sum_{t=1}^T d_t} \cdot e^{-y_i f_t(x_i)}$  unde  
 $f_t(x) = \sum_{t=1}^T d_t f_t(x)$  (marginea algebraică);  
 $\text{marg } (f_T) \leq \frac{1}{T} \sum_{t=1}^T \delta_t$ ;  
 $\frac{1}{T} \sum_{t=1}^T \delta_t \leq \frac{1}{n} \sum_{t=1}^T \delta_t^2$  ( $\delta_t = \frac{1}{2} - \epsilon_t$ );  
 AdaBoost este un algoritm de optimizare  
 sevențială (la fiecare iterată, își  
 optimizează și în funcție de  $d_t$ );  
 ↳ slides DT, de la slide-ul 23;  
 garantie de învățare empirică și stabilitate  $\Leftrightarrow$   
 dacă există un  $\delta > 0$  astfel încât  $\frac{1}{T} \sum_{t=1}^T \delta_t \leq \delta$ ,  
 și pentru  $t = \frac{1}{T}$ , atunci după un număr  
 m. de iterări, inversa la conținut este  
 strict mai mică decât un r. conținut fixat  
 $(\epsilon \leq \frac{1}{T}) \Rightarrow$  menține la conținut 0);

→ condiție de învățabilitate și -solabilă ( $\Rightarrow$ )  
 $\text{erors}(HT) \leq \sum_{t=1}^T \epsilon_t^2$ ;

## SĂPTĂMÂNA 10

- AdaBoost produce overfitting atunci când datele de antrenament și cele de test sunt foarte mixte
- învățare supravezută  $\Leftrightarrow$  clasificare, regresie;
- învățare ne-supravezută  $\Leftrightarrow$  clusterizare;
- regresie  $\Leftrightarrow$  aproximare de funcții de probabilitate;
- învățare ne-supravezută  $\Leftrightarrow$  nu mai avem etichete fizice instante de antrenament;
- clusterizare (clustering)  $\Leftrightarrow$  grupare;
- distanță / măsură de distanță  $\Rightarrow$  reprezentare fizică etichetelor;
- similaritate  $\Leftrightarrow$  măsură ce ne arată că de similaritate sunt 2 cluze;
- clusterizare  $\begin{cases} \text{împărțire} \\ \text{mijlocuri} \end{cases}$  (algoritmul K-means și algoritmul EM);  
K-means este inversul distanței  $\Leftrightarrow$  ca căt similaritatea este mai mare, ca căt căt distanța este mai mare;
- similaritatea este mai mare, ca căt căt distanța este mai mică, ca căt căt similaritatea este mai mare;

- "single-linkage" (nearest-neighbour)  $\Leftrightarrow$   
 $d(A, B) = \min \{ d(x, y) \mid x \in A, y \in B \};$
- "complete-linkage" (furthest-neighbour)  $\Leftrightarrow$   
 $d(A, B) = \max \{ d(x, y) \mid x \in A, y \in B \};$
- "average-linkage"  $\Leftrightarrow d(A, B) = \frac{1}{|A||B|} \sum_{y \in B} d(x, y);$
- A, B sunt 2 clustere; bottom-up;  
 → clusterizare se face top-down;
- clusterizarea este proporțională cu similaritatea (cu cat similaritatea este mai mare, cu atat similaritatea este mai mică);
- dendrogramme  $\Leftrightarrow$  arborii fizice desfășurate  
 și se face;
- în general ~~se~~ dendrogramme se fac bottom-up;
- initial considerăm că fiecare instantă este cluster singlet;
- în primul moment se formează (se formează combinația a căror 2; nu există la vecinie directă cluster prima și al doilea nu sunt cluster care se împobeză pe totul);
- algoritmul bottom-up:

→ trăsănd și paralelă cu axa orizontală unde distanța dintre cluster este maximă. Se obține pe cale de care se căștigă material;

↳ carte ML, pag. 755:

- în mod implicit lucru cu distanță euclidiană, dacă nu este specificată altă;
- putem lucra cu valoarea opătizată a unei ierarhii (în plan);

↳ carte ML, pag. 752:

- "single-linkage" și "complete-linkage" clustere "elongate" (elongate, enginerei);
- "complete-linkage" și "average-linkage" au tendință să formeze clustere de formă
- tendință să formeze și "formă" mai deosebită și "compactă";
- rezultatul (ierarhie) obținut nu sunt determinate neapărat în mod unic (maximum de similaritate între 2 atomi de mai multe pasihi);

↳ book - overview, pag. 32:

- dacă avem cinci sau zece "single-linkage" și "complete-linkage" și astăzi dendogramme identice, nu rezultă în mod neapărat că "single-linkage" și "complete-linkage" vor obține același rezultat.

dendrogramă;

↳ carte ML, pag. 761;

$$\rightarrow d(x \cup y, z) = \frac{lx|d(x, z) + ly|d(y, z)}{|x| + |y|};$$

→ faza lucru și cu matrice de distanțe;

↳ slides cluster, de la slide-ul 4;

→ clusterizare top-down (devizivă)  $\Leftrightarrow$  initial formim de la un cluster cu toate instanțe, și el devine deosebit de aproape de o funcție de coeziune ( $c_{\text{sh}}(A) = \frac{|A|}{\sum d(x, y)}$ ) și

sună de split (identificăm clusterele ca și subcluster); facem acesta deviziv și continuă cea mai mică și se spargem în

↳ slides cluster, de la slide-ul 10;

→ m. maxim de similaritate dintre dendrogramă (văzută ca arbore) să minimizăm este  $\text{faza } n/2$ , unde este  $n-1$ , iar cea de minim este  $\text{faza } n/2$  (afuzilor)

→ există și numeroase tipuri de instanțe de clusterizat;

există și numeroase tipuri de instanțe corespondente sunt de similaritate de

clusterizare ierarhică, și oferă arborele de

"single-linkage", și este minima dintre-un graf;

"complete-linkage", și este suma dintre-un graf;

"denta-un graf";

- clusteringul partitura  $\Leftrightarrow$  clusterizare
- menținabilitate; execuție algoritmului K-means
- pe parcursul ~~execuției~~ algoritmului K-means
  - K este fixat ( $K \geq 2$ ); K reprezintă cate clusteruri sunt formate (clusteruri sunt disjuncte);
  - se formează K-partiție;
  - ↳ formarea K-partiție, funcție de calcul al
- $\mu: P(\mathbb{R}^m) \rightarrow \mathbb{R}^m$  ( $\Leftrightarrow$  funcție de calcul al mediei;
- centroïd ( $\Leftrightarrow$  centru de greutate);
- ↳ se alege initial  $\mu_1, \dots, \mu_K$  din  $\mathbb{R}^m$ ;
- $X = \{x_1, \dots, x_m\} \subseteq \mathbb{R}^m$  set de date;
- d ( $\Leftrightarrow$  măsură de distanță) din  $\mathbb{R}^m$ ;
- la fiecare pas formam K clusteruri și măsurăm instanțele care sunt cele mai apropiate de centroïdul respectiv;
- rezultatul lui K-means nu este neapărat unic;
- după ce alcătuim clusterul, punem centrulii în poziții mai bune ( $\mu_j = \mu(c_j)$ ,  $c_j$  este un cluster);
- ↳ centrulii chiar devin centri de greutate;
- criteriu de oprire neobișnuit ( $\Leftrightarrow$  continuu)
- se reorganizează clusterul;

- ↳ carte ML, pag. 769;  
 → condiții de oprire  $\Leftrightarrow$  pînă când compunente  
 clusterelor nu se mai modifică de la o  
 iteratie la alta sau pînă când posibile  
 schimbari nu se mai schimbă de la o  
 iteratie la alta (cîte 2 criterii nu sunt  
 independente simultan);  
 reprezentat îndependente singurătate;  
 → scădere  $\Leftrightarrow$  punet singurătate;  
 → K-means poate să producă rezultate diferențiate;  
 → în funcție de initializare diferențiate,  
 valoarea a "calitatei" clusterelor  
 (funcție de "coherență" / "distorsiune" / "energie"  
 totală)  $\Leftrightarrow$  sumă celor mai mici "gături",  
 $J_K(c, \mu) = \sum \|x_i - \mu_c(x_i)\|^2$ , unde c este  
 K-partiție,  $\mu$  este K-configurație  
 și  $\mu_c(x_i)$  este centrulidul cel mai apropiat  
 de  $x_i$ ;  
 → rezultatul lui K-means poate să difere în  
 funcție de <sup>masura de</sup> distanță folosită (chiar dacă  
 avem aceeași initializare);  
 → K-means este sensibil la prezența  
 setărilelor;  
 ↳ carte ML, pag. 775;  
 → dacă pe parcursul execuției lui K-means un  
 cluster este vid, centrulidul respectiv nu-zi  
 schimbă poziție la următoarea iteratie;

- Înainte de K-means, este bine să se aplică un algoritm de identificare al clusterelor;
- atunci când lucram cu distanță euclidiană separația dintre cluster la k-means sunt de tip limitat;

### SĂPTAMÂNILE 11-14

- algoritmul EM (Expectation - Maximization)  $\Leftrightarrow$  permite crearea unor modele probabiliste care pe de sine, depind de un set de parametri  $\theta$ , iar pe de altă parte, includ și lărge variabile observabile ("observabile sau "înibile") și variabile necunoscute sau ("necunoscibile", "occulte" sau "latente");
- în general, în cadrul de situații / modele, nu se poate face în mod direct și estimare a parametrilor modelului ( $\theta$ ) în ceea ce încât să se garantize atingererea maximului verosimilității datelor observabile  $x$ ;
- algoritmul EM procedează în manieră iterativă constituind modalitate convenabilă de estimare a parametrilor  $\theta$ ;
- log-verosimilitatea datelor observabile ( $x$ )  $\Leftrightarrow$   $\log P(x|\theta)$ ;
- log-verosimilitatea datelor complete (observabile și neobservabile,  $x, z$ )  $\Leftrightarrow \log P(x, z|\theta)$ ;

- log-verosimilitatea datelor observabile ( $x$ ) și probabilitatea lor de a fi generate de funcție de datele măsurabile ( $z$ )  $\Leftrightarrow$   
 exprimă log-verosimilitatea datelor observabile ( $x$ )  $\Leftrightarrow$   
 $I(\theta) = \log p(x|\theta) = \log \left( \prod_{i=1}^n p(x_i, z_i | \theta) \right);$
- $g \Leftrightarrow$  o funcție / distribuție de probabilitate definită  
 pe o variabilă censură / măsurabilă  $z$ ;  
 $\rightarrow \log p(x|\theta) \geq \sum_{i=1}^n g(x_i) \log \left( \frac{p(x_i, z_i | \theta)}{g(x_i)} \right), \forall x$  (fixat),  
 $\forall \theta \ni g$  distribuție probabilistică pe  
 variabilă măsurabilă  $z$ ;  
 $\rightarrow$  variația log-verosimilității este  
 o funcție de forma  $F(g, \theta) = \sum_{i=1}^n g(x_i) \log \left( \frac{p(x_i, z_i | \theta)}{g(x_i)} \right)$   
 $\hookrightarrow$  o nouă funcție de formă  
 constituie o margină informatică pentru  
 funcția de log-verosimilitate a datelor  
 incomplete / observabile,  $I(\theta) = \log p(x|\theta);$   
 incompletă și variabilă de tip funcțional;  
 $\rightarrow g \Leftrightarrow$  să  $g$  este o variabilă de tip o medie,  
 $\rightarrow$  expresie funcției  $g$  este de tip o parametru  
 $E[g] \left[ \log \frac{p(x, z | \theta)}{g(x)} \right]$ , atunci când  $x, z$  și parametru  
 $\theta$  se consideră fixe, ion  $g$  este lăsat să  
 varieze;
- inegalitatea lui Jensen  $\Leftrightarrow$  considerând  $x$  și variabila  
 obiectivă ( $z$ ), dacă  $\varphi$  este o funcție convexă și  
 concavă, atunci  $\varphi(E[x]) \leq E[\varphi(x)]$  și dacă  $\varphi$   
 este o funcție concavă, atunci  $\varphi(E[x]) \geq E[\varphi(x)];$   
 este o funcție relativă (divergență Kullback - Leibler)  $\Leftrightarrow$   
 $KL(g(z) || p(z|x, \theta)) = -\sum_{i=1}^n g(x_i) \log \frac{p(x_i, z_i | \theta)}{g(x_i)};$
- $\rightarrow \log p(x|\theta) = F(g(x), \theta) + KL(g(x) || p(x|x, \theta));$   
 $\hookrightarrow$  divergența dintre funcția obiectivă  
 $I(\theta) = \log p(x|\theta)$  și marginea sa informatică  
 $F(g(x), \theta)$  este  $KL(g(x) || p(x|x, \theta));$

- Înlocuiește maximul funcției de log-verosimilitate  $\log \mathcal{P}(x|\theta)$  în raport cu  $\theta$ , algoritmul EM va maximiza marginea sau inferioară,  $\mathbb{F}(\mathcal{Q}(z), \theta)$ , în raport cu combinația argumentelor,  $\mathcal{Q}(z)$  și  $\theta$  ;
- punctul a cărui maximul (nu maxim local  
 a) marginii inferioare  $\mathbb{F}(\mathcal{Q}(z), \theta)$ , algoritmul EM aplică metoda curenții pe coordonate  $\Leftrightarrow$  după a initial  $\Rightarrow$  se fixează  $\theta^{(t)}$  eventual obținut,  
 și maximizarea iterativ funcția  $\mathbb{F}(\mathcal{Q}(z), \theta)$  în mod alternativ (mai întâi în raport cu  
 distribuția  $\mathcal{Q}(z)$  și apoi în raport cu parametrii  
 $\theta$ ) ;
- } • punct E  $\Leftrightarrow \mathcal{Q}^{(t)}(z) = \underset{\mathcal{Q}(z)}{\operatorname{argmax}} \mathbb{F}(\mathcal{Q}(z), \theta^{(t)})$  ;  
 • punct M  $\Leftrightarrow \theta^{(t+1)} = \underset{\theta}{\operatorname{argmax}} (\mathbb{F}(\mathcal{Q}^{(t)}(z), \theta))$  ;
- $\mathcal{P}(B \cap C | A) = \mathcal{P}(B|A) \cdot \mathcal{P}(C|A, B)$  ;  
 →  $\text{KL}(\mathcal{P} \parallel \mathcal{Q}) \geq 0$ , + p. 2  $\Rightarrow \text{KL}(\mathcal{Q}(z) \parallel \mathcal{P}(z|x, \theta)) \geq 0$  ;
- dacă  $\theta^{(t)}$  este valoarea obținută punctul parametru  
 și parametrii  $\theta$  la iteratăt a algoritmului  
 EM și considerând această valoare fixată, atunci  
 maximul lui  $\mathcal{Q}(z)$  în raport cu argumentul /  
 distribuția  $\mathcal{Q}(z)$  este atâtă punctul distribuția  
 $\mathcal{P}(z|x, \theta^{(t)})$  și valoarea maximului este  
 $\max_{\mathcal{Q}(z)} \mathbb{F}(\mathcal{Q}(z), \theta^{(t)}) = E_{\mathcal{P}(z|x, \theta^{(t)})} [\log \mathcal{P}(z|x, \theta^{(t)})] +$   
 $+ H(\mathcal{P}(z|x, \theta^{(t)}))$  ;

- $\rightarrow KL(\pi || \theta) \geq 0$  și  $KL(\pi || \theta) = 0 \Leftrightarrow \pi = \theta$ ;  
 $\rightarrow E[X - Y] = E[X] - E[Y]$ ;  
 $\rightarrow$  dacă suntem  $\theta(\theta(t)) = E_{\pi}[\pi | X, \theta(t)] [\log \pi(x, z | \theta)]$   
 și  $G_t(\theta) = \mathbb{H}[\pi(\pi | X, \theta(t)), \theta]$ , atunci  
 $G_t(\theta(t)) = \log(\pi | \theta(t)) = \theta(\theta(t) | \theta(t)) + \mathbb{H}[\pi(\pi | X, \theta(t))]$ ;  
 și  $G_t(\theta) = \theta(\theta | \theta(t)) + \mathbb{H}[\pi(\pi | X, \theta(t))]$ ;  
 $\hookrightarrow \mathbb{H}[\pi(\pi | X, \theta(t))] nu\ depende\ de\ \theta \Rightarrow$   
 $\arg\max_{\theta} G_t(\theta) = \arg\max_{\theta} \theta(\theta | \theta(t))$ ;  
 $\arg\max_{\theta} \mathbb{H}[\pi(\pi | X, \theta(t)), \theta] = \arg\max_{\theta} G_t(\theta) =$   
 $\rightarrow \theta(t+1) = \arg\max_{\theta} \mathbb{H}[\pi(\pi | X, \theta(t)), \theta];$   
 $= \arg\max_{\theta} \theta(\theta | \theta(t));$   
 $\left. \begin{array}{l} \text{reformularea algoritmului EM (ca ușoară)} \\ \cdot pasul E' \leftrightarrow calculate \theta(\theta | \theta(t)) = \\ \quad = E_{\pi}[\pi | X, \theta(t)] [\log \pi(X, z | \theta)], \\ \cdot pasul M' \leftrightarrow calculate \theta(t+1) = \\ \quad - \arg\max_{\theta} \theta(\theta | \theta(t)); \end{array} \right\}$   
 $\rightarrow \theta(\theta | \theta(t)) \leftrightarrow media\ log-verosimilității dateelor$   
 complete (observabile și neobservabile) în  
 raport cu distribuția conditională  $\pi(\pi | X, \theta(t))$ ;  
 $\rightarrow$  dacă considerăm iterabilă  $t=0, 1, \dots$  și  
 $\theta(t+1) = \arg\max_{\theta} \theta(\theta | \theta(t))$  ( $\theta(t)$  este mediu arbitrat), atunci pentru orice  $t$  fixat (arbitrat)  
 și pentru orice  $\theta$  avem  $\theta(\theta | \theta(t)) \geq \theta(\theta | \theta(t))$

are locuine neegalitatea  $\log p(x|\theta) - \log p(x|\theta(t)) \geq$   
 $\geq \theta(\theta/\theta(t)) - \theta(\theta(t)/\theta(t))$ ;

↳ aceeași combinație a valorii funcției auxiliare  $\theta(\theta/\theta(t))$  conduce la o combinație de putere la fel de mare a valorii funcției obiectiv  $I(\theta)$ ; deci combinația  $\theta \in \theta^{*(t+1)} = \arg\max_{\theta} \theta(\theta/\theta(t))$ , astfel încât  $\log p(x|\theta(t+1)) \geq \log p(x|\theta(t))$  atunci  $\log p(x|\theta(t+1)) \geq \log p(x|\theta(t))$  (în final, vom avea  $I(\theta(0)) \leq I(\theta(t)) \leq I(\theta(t+1))$ );

$\Leftrightarrow \dots$ ;

→ verificarea "generalizării" a algoritmului EM  $\Leftrightarrow$   
 deoarece M la iteratia t a algoritmului EM,  
 este suficient ca înlocuind  $\theta(t+1) =$   
 $= \arg\max_{\theta} \theta(\theta/\theta(t))$ , să se obțină nouă  
 înlocuind  $\theta(\theta(t+1)/\theta(t)) \rightarrow \theta(\theta(t)/\theta(t))$ ;  
 și căderea în buclă  $\Leftrightarrow \theta(\theta(t)/\theta(t)) \geq \arg\max_{\theta} \theta(\theta(t)/\theta(t))$ ;

→ neegalitatea lui Gibbs  $\Leftrightarrow E[g(x)] = \sum_x g(x) p(x)$

→  $E[X] = \sum_x x \cdot p(x)$  și

(pentru variabile discrete);

→ teorema lui Bayes (3 variabile)  $\Leftrightarrow$

$p(R|H,S) = \frac{p(H|R,S)p(R|S)}{p(H|R,S)p(R|S) + p(H|\neg R,S)p(\neg R|S)}$ ;

→ se dă  $x = x_1, \dots, x_m$  (date observabile)  
 generat independent cu ajutorul distribuțiilor  
 spuseelor  $s_1, \dots, s_m$  și  $\tilde{x} = \tilde{x}_1, \dots, \tilde{x}'_m$  (date  
 nedeobservabile) și se cere determinarea  
 lui  $p(x|\theta)$ ;

(date maximizată (fără)  $p(x|\theta)$ );



- algoritmul EM pentru distribuție Bernoulli:
- initializare  $\leftrightarrow$  atribuire de valori arbitrară pentru parametrii  $\pi, \rho$  și  $g(\pi(t), \rho(t))$  și  $l_g(t)$  în intervalul  $(0,1)$ ;
  - pentru  $t = 0, \dots, T-1$  ( $T$  fixat) (cum sănătatea sănătății și log-verosimilitatea datei obserabile nu mai crește semnificativ sau sănătatea și  $|l_g(t) - l_g(t+1)| < \epsilon$ ,  $|\rho(t) - \rho(t+1)| < \epsilon$  și  $|l_g(t) - l_g(t+1)| < \epsilon$ , și fixat), execută pașul E și pașul M;
  - pașul E  $\leftrightarrow$  pentru  $i = 1, n$ , calculăzi
$$\mu_i(t) = \frac{(p(t)x_i + (1-p(t))(1-x_i)) \cdot \pi(t) + g(t)x_i}{(1-g(t))(1-\pi(t))}$$
  - pașul M  $\leftrightarrow$  calculăzi
$$\pi(t+1) = \frac{S\pi(\rho|g(t))}{S\rho} = \frac{\sum_{i=1}^n \mu_i(t)x_i}{\sum_{i=1}^n \mu_i(t)}$$

$$g(t+1) = \frac{\sum_{i=1}^n (1-\mu_i(t))x_i}{\sum_{i=1}^n (1-\mu_i(t))} \quad \text{și} \quad \pi(t+1) = 1 - \sum_{i=1}^n \mu_i(t)$$
  - returnează  $\pi(t+1), \rho(t+1)$  și  $g(t+1)$ ;

- la AdaBoost, e suficient să punem un prag extins pe una din aceste componente sau după teste fizicale);
- distribuție binomială  $\leftrightarrow X \sim B(m, p)$ ,  $E[X] = mp$ ,
- $Var(X) = mp(1-p)$ , unde  $m$  este nr. de repetări și  $p$  este probabilitatea;
- clusterează ( $\Rightarrow$  se agrupează după distanță minimă);

$\rightarrow$  metricea lui Ward  $\Leftrightarrow D(x, y) = \sum_{i \in x} \|x_i - \mu_{xy}\|^2 -$   
 $- \sum_{i \in y} \|x_i - \mu_x\|^2 - \sum_{i \in y} \|x_i - \mu_{xy}\|^2$  ( $\|x_i - \mu_{xy}\|^2$  este  
 norma la patrat  $\Leftrightarrow$  distanța dintre  $x_i$  și  
 centrul  $x_{\bar{y}}$ , adică media aritmetică a tuturor  
 punctelor din  $x_{\bar{y}}$   $\Leftrightarrow \|x_i - \mu_{xy}\|^2 = (\sqrt{(x_{i1} - \mu_{xy})^2 +$   
 $+ (x_{i2} - \mu_{xy})^2})^2$ ).

$\hookrightarrow$  punctul matricial initial de clusterizare,  
 Iulian distanța dintre 2 puncte, și adică  
 la sfârșit și implementăm la 2;

$$\rightarrow \mu_x = \frac{1}{m_x} \sum_{i \in x} x_i$$


centrul  $x$ ;

$$\rightarrow D(x, y) = \frac{m_x m_y}{m_x + m_y} \| \mu_x - \mu_y \|^2;$$

## EXERCITII TEST 2

Ex. 1

Algorithm AdaBoost:  $T=3$ ;



- frontieră  $T=1$ , vom avea separatorii  $\frac{1}{2}, \frac{5}{2}, \frac{9}{2}$  pentru  $x_1$  și  $(\frac{1}{2} \text{ prob exterior})$  și  $\frac{1}{2}, \frac{3}{2}, \frac{5}{2}, \frac{7}{2}$  pentru  $x_2$
  - $x_1 (\frac{1}{2} \text{ prob interior})$ ; initial  $x_i$  au probabilitățile  $\frac{1}{3}$  ( $\frac{1}{2} \text{ prob interior}$ ); initial  $x_i$  au probabilitățile  $\frac{1}{3}$   $\forall i = 1, 2$ ;
  - |   |               |               |                             |
|---|---------------|---------------|-----------------------------|
| $\Rightarrow$                               | $\frac{1}{2}$ | $\frac{5}{2}$ | $\frac{9}{2}$               |
| $\text{err}_{\frac{1}{2}}(x_1 < \infty)$    | $\frac{4}{9}$ | $\frac{2}{9}$ | $\frac{6}{9} = \frac{2}{3}$ |
| $\text{err}_{\frac{1}{2}}(x_1 \geq \infty)$ | $\frac{5}{9}$ | $\frac{7}{9}$ | $\frac{1}{9}$               |
  - |   |               |               |                             |               |
|---|---------------|---------------|-----------------------------|---------------|
| $\Rightarrow$                               | $\frac{1}{2}$ | $\frac{3}{2}$ | $\frac{5}{2}$               | $\frac{7}{2}$ |
| $\text{err}_{\frac{1}{2}}(x_2 < \infty)$    | $\frac{4}{9}$ | $\frac{4}{9}$ | $\frac{3}{9} = \frac{1}{3}$ | $\frac{2}{9}$ |
| $\text{err}_{\frac{1}{2}}(x_2 \geq \infty)$ | $\frac{5}{9}$ | $\frac{5}{9}$ | $\frac{2}{9}$               | $\frac{7}{9}$ |
  - $x_1 < \infty \Rightarrow -1, x_2 > \infty \Rightarrow +1, x < \infty$  și frontieră
  - $x_1 < \infty \Rightarrow -1, x_2 > \infty \Rightarrow +1, x < \infty$  (+, - frontieră  $x_1 < \infty$ ) și  $-+, +$  frontieră  $x_1 \geq \infty$ ;
  - ecuarea fundamentală minimizând diferența este  $\frac{2}{9} = 0.222$

$x_1$  es el primer punto,  $x_2 < \frac{t}{2} < x_1$ ,  $x_1 < \frac{t}{2}$ ;  
 ↪ algoritmo  $x_2 < \frac{t}{2} \Rightarrow f_1 = \text{sign}\left(\frac{t}{2} - x_2\right)$ ;

$$\cdot f = \text{sign}(x - t) = \begin{cases} -1, x < t \\ +1, x \geq t \end{cases}$$

$$\cdot f = \text{sign}(x - y) = \begin{cases} +1, x \geq y \\ -1, x < y \end{cases}$$

$x < y$

$x \geq y$

para la siguiente:

$x_4$  y  $x_5$  son los siguientes:

$$\cdot x_1 = \frac{t}{2} - \epsilon_1 = \frac{t}{2} - \frac{\beta^2}{18} = \frac{9-4}{18} = \frac{5}{18};$$

$x_2, x_3, x_6, x_7, x_8$  siguen.

$$\cdot M = \{x_4, x_5\}, C = \{x_1, x_2, x_3, x_6, x_7, x_8\}$$

$$\cdot D_1(i) = \frac{t}{g}, \quad t \geq 1, g \geq 1;$$

$$\cdot D_2(i) = \begin{cases} \frac{D_1(i)}{g\epsilon_1}, & i \in K \\ \frac{D_1(i)}{2(1-\epsilon_1)}, & i \in C; \end{cases}$$

$$\cdot \frac{D_1(i)}{g\epsilon_1} = \frac{\frac{t}{g}}{\frac{g}{2} \cdot \frac{\beta^2}{18}} = \frac{t}{g} \cdot \frac{18}{\beta^2} = \frac{t}{4};$$

$$\cdot \frac{D_1(i)}{2(1-\epsilon_1)} = \frac{\frac{t}{g}}{\frac{t}{2} \left(1 - \frac{\beta^2}{18}\right)} = \frac{\frac{t}{g}}{\frac{t}{2} \cdot \frac{17}{18}} = \frac{t}{g} \cdot \frac{18}{17} = \frac{t}{\frac{17}{9}};$$

$$D_2(i) = \begin{cases} \frac{t}{4}, & i \in K \\ \frac{t}{\frac{17}{9}}, & i \in C; \end{cases}$$

- function iterative  $T=2$ , von area separation  $\frac{1}{2}$ ,
- $\frac{\pi}{2}, \frac{3\pi}{2}$  function  $x_1 \neq \frac{1}{2}, \frac{3}{2}, \frac{\pi}{2}, \frac{7}{2}$ ;

$y$	$\frac{\pi}{2}$	$\frac{3\pi}{2}$	$\frac{7}{2}$
$\text{var}_{D_1}(x_1 < y)$	$\frac{1}{14} = \frac{3}{4}$	$\frac{3}{14} = \frac{1}{4}$	$\frac{1}{14} + \frac{3}{4} = \frac{11}{14}$
$\text{var}_{D_2}(x_1 \geq y)$	$\frac{3}{4}$	$\frac{1}{6}$	$\frac{3}{14}$

$y$	$\frac{\pi}{2}$	$\frac{3\pi}{2}$	$\frac{7}{2}$	$\frac{11}{2}$
$\text{var}_{D_1}(x_2 < y)$	$\frac{1}{14} = \frac{3}{4}$	$\frac{1}{4} + \frac{3}{14} = \frac{13}{28}$	$\frac{1}{14} + \frac{1}{4} = \frac{15}{28}$	$\frac{3}{4} = \frac{21}{28}$
$\text{var}_{D_2}(x_2 \geq y)$	$\frac{3}{4}$	$\frac{5}{28}$	$\frac{10}{28}$	$\frac{1}{2}$

- we can consider minimum in antecedent state  $\epsilon_2 = \frac{1}{7}$  if we obtain function  $x_1 < \frac{\pi}{2}$ ;
- $f_2 = \text{sign}\left(\frac{y}{2} - x_1\right)$ ;
- $\delta_2 = \frac{1}{2} - \epsilon_2 = \frac{1}{2} - \frac{1}{7} = \frac{7-2}{14} = \frac{5}{14}$ ;
- $D_2(i) = \text{instantaneous classification unit}$
- $D_2(i) = \text{inst. } x_1 < x_2$ ;
- $D_2(i) = \begin{cases} \frac{D_1(i)}{2\epsilon_2}, & i \in \{2, 3\}; \\ \frac{D_1(i)}{2(1-\epsilon_2)}, & i \notin \{2, 3\}; \end{cases}$
- $\frac{D_1(i)}{2\epsilon_2} = \frac{\frac{3}{14}}{2 \cdot \frac{1}{7}} = \frac{1}{4} \cdot \frac{7}{2} = \frac{7}{8}$ ;
- $\frac{D_1(i)}{2(1-\epsilon_2)} = \frac{D_1(i)}{2 \cdot \frac{6}{7}} = \frac{D_1(i)}{12/7} =$

$$\left\{ \begin{array}{l} \frac{1}{4} \\ \frac{1+6}{4 \cdot 12} = \frac{1}{4} \cdot \frac{7}{12} = \frac{1}{24}; \end{array} \right.$$

$$\frac{1}{2 \cdot \frac{6+7}{4}} = \frac{1}{4} \cdot \frac{7}{12} = \frac{7}{48};$$

$$\hookrightarrow D_3(i) = \left\{ \begin{array}{l} \frac{1}{4}, i \in \{8; 9\}; \\ \frac{7}{24}, i \in \{4; 5\}; \end{array} \right.$$

$$\frac{1}{24}, i \notin \{4; 5; 8; 9\};$$

$$\frac{1}{24}, i \notin \{4; 5; 8; 9\};$$

• centre  $T=3$ , calculate mobile generate to

contractive:

	$\pi/2$	$5\pi/24$	$3\pi/2$
$\sin D_3(x_1 < \pi)$	$\frac{7}{12}$	$\frac{3}{4} = \frac{1}{2}$	$\frac{21}{24}$
$\sin D_3(x_1 \geq \pi)$	$\frac{5}{12}$	$\frac{1}{2}$	$\frac{3}{24} = \frac{1}{8}$

$$\bullet \frac{3}{24} + \frac{3}{4} = \frac{1}{12} + \frac{1}{2} = \frac{1+6}{12} = \frac{7}{12};$$

~~$$\bullet \frac{3}{24} + \frac{2+7}{48} + \frac{3}{4} = \frac{1+7+12}{48} = \frac{20}{48} = \frac{5}{12};$$~~

$$\bullet \frac{3}{24} + \frac{2+7}{48} + \frac{1}{2} = \frac{2+7+12}{24} = \frac{21}{24};$$

	$\pi/2$	$3\pi/24$	$5\pi/24$	$7\pi/24$
$\sin D_3(x_2 < \pi)$	$\frac{7}{12}$	$\frac{23}{48}$	$\frac{1}{3}$	$\frac{7}{24}$
$\sin D_3(x_2 \geq \pi)$	$\frac{5}{12}$	$\frac{25}{48}$	$\frac{21}{3}$	$\frac{17}{24}$


- $\frac{2}{24} + \frac{2}{24} = \frac{4}{24};$
- $\frac{5}{24} + \frac{2}{24} + \frac{1}{24} = \frac{7}{24} + \frac{1}{12} + \frac{1}{4} = \frac{7+4+12}{48} = \frac{23}{48};$
- $\frac{2}{24} + \frac{1}{24} = \frac{3}{24} + \frac{1}{24} = \frac{8}{24} = \frac{1}{3};$
- $\frac{2}{24} = \frac{1}{24};$
- fundamentale minima to entrance list  
 $x_1 > \frac{9}{4};$
- minima to obtain further
- $e_3 = \frac{1}{8}$  if we obtain further
- $\hookrightarrow f_3 = \text{sign} \left( x_1 - \frac{9}{4} \right);$
- $f_3 = \frac{1}{2} - e_3 = \frac{1}{2} - \frac{1}{8} = \frac{4-1}{8} = \frac{3}{8};$
- $D_3 = \frac{1}{2} - e_3$  characterize event  $x_1, x_2;$
- instantaneous point,  $i \in \{1, 2\};$
- $D_4(i) = \begin{cases} \frac{D_3(i)}{2e_3}, & i \in \{1, 2\}; \\ \frac{D_3(i)}{2(1-e_3)}, & i \notin \{1, 2\}; \end{cases}$
- $\frac{D_3(i)}{2e_3} = \frac{\frac{1}{24}}{\frac{2}{24}} = \frac{1}{24} \cdot \frac{4}{1} = \frac{1}{6}; \quad \frac{1}{24} \cdot \frac{2}{3} = \frac{1}{24} \cdot \frac{4}{3} = \frac{1}{18};$
- $\frac{D_3(i)}{2(1-e_3)} = \frac{D_3(i)}{2 \cdot \frac{3}{8}} = \begin{cases} \frac{\frac{1}{24}}{\frac{3}{8}} = \frac{1}{24} \cdot \frac{8}{3} = \frac{1}{36}, \\ \frac{\frac{1}{24}}{\frac{3}{8}} = \frac{1}{24} \cdot \frac{8}{3} = \frac{1}{36}; \end{cases}$
- $\hookrightarrow D_4(i) = \begin{cases} \frac{1}{6}, & i \in \{1, 2\}; \\ \frac{1}{18}, & i \in \{3, 4, 5, 6\}; \\ \frac{1}{36}, & i \in \{7, 8, 9\}; \\ \frac{1}{13}, & i \in \{10, 11, 12\}; \end{cases}$

$$\begin{aligned}
 & \cdot d_1 = \frac{1}{\sqrt{2}} \log \frac{1-\varepsilon_1}{\varepsilon_1} = \frac{1}{\sqrt{2}} \log \left| \frac{1-\sqrt{2}}{\sqrt{2}} \right| = \frac{1}{\sqrt{2}} \log \frac{\sqrt{2}}{\sqrt{2}} = \\
 & = \log \left( \frac{\sqrt{2}}{\sqrt{2}} \right)^{1/2} = \log \sqrt{2} ; \\
 & \cdot d_2 = \frac{1}{\sqrt{2}} \log \frac{1-\varepsilon_2}{\varepsilon_2} = \frac{1}{\sqrt{2}} \log \frac{1-\frac{1}{\sqrt{2}}}{\frac{1}{\sqrt{2}}} = \frac{1}{\sqrt{2}} \log \frac{\sqrt{2}-1}{1} = \\
 & = \log \left( \frac{\sqrt{2}-1}{1} \right)^{1/2} = \log \sqrt{2} ; \\
 & \cdot d_3 = \frac{1}{\sqrt{2}} \log \frac{1-\varepsilon_3}{\varepsilon_3} = \frac{1}{\sqrt{2}} \log \left| \frac{1-\sqrt{2}}{\sqrt{2}} \right| = \frac{1}{\sqrt{2}} \log \frac{\sqrt{2}}{\sqrt{2}} = \\
 & = \log \left( \frac{\sqrt{2}}{\sqrt{2}} \right)^{1/2} = \log \sqrt{2} ; \\
 & \cdot H_3 = \operatorname{sign} \left( \sum_{i=1}^3 d_i \cdot f_i \right) = \operatorname{sign} \left( \log \sqrt{2} \cdot \operatorname{sign} \left( \frac{x_1 - t_1}{\sqrt{2}} \right) + \right. \\
 & \quad \left. + \log \sqrt{2} \cdot \operatorname{sign} \left( \frac{x_2 - t_2}{\sqrt{2}} \right) + \log \sqrt{2} \cdot \operatorname{sign} \left( \frac{x_3 - t_3}{\sqrt{2}} \right) \right) = \\
 & = \operatorname{sign} \left( \log \sqrt{2} - \log \sqrt{2} + \log \sqrt{2} \right) = \\
 & = \operatorname{sign} \left( \log \left( \sqrt{2} \cdot \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} \right) \right) = \\
 & = \operatorname{sign} \left( \log \left( \frac{\sqrt{2}}{\sqrt{2} \cdot \sqrt{2}} \cdot \frac{1}{\sqrt{2}} \right) \right) = \\
 & = \operatorname{sign} \left( \log \left( \frac{1}{\sqrt{2}} \cdot \frac{1}{\sqrt{2}} \right) \right) = \operatorname{sign} \left( \log \frac{1}{2} \right) = \\
 & = \operatorname{sign} \left( -\log \frac{1}{2} \right) = -1 ; \\
 & \cdot \operatorname{sign}(H_T) = \begin{cases} \sqrt{2}, & T=1 \\ 0, & T=2 \\ 0, & T=3 \end{cases} ;
 \end{aligned}$$

T	$d_T$	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$
1	$\ln\sqrt{12}$	+1	+1	-1	+1	+1	-1	-1	+1	+1 +1
2	$\ln\sqrt{6}$	+1	+1	-1	-1	-1	-1	-1	-1	-1 -1
3	$\ln\sqrt{7}$	-1	-1	-1	-1	-1	-1	+1	+1	+1
	$\#(x_i)$	+1	+1	-1	-1	-1	-1	-1	+1	+1

•  $H_3(x_i) = \text{sign}(\ln\sqrt{7} \cdot \text{sign}(\frac{7}{2} - x_{i,2})) +$   
 $+ \ln\sqrt{6} \cdot \text{sign}(\frac{5}{2} - x_{i,1}) + \ln\sqrt{7} \cdot \text{sign}(x_{i,1} - \frac{5}{2}))$ ;

**Ex. 2**



$$x_1 = 1, x_2 = 3, x_3 = 5;$$

- a) valoarea ponderilor initial:  
 primul campus decisional;  
 probabilitatile instantelor după  $T=1$ ;

- avem 3 instante de curențirement  $\Rightarrow$   
 $D_1(i) = \frac{1}{3}, \forall i = 1, 3$ ;


$$\text{separatii sunt } 0, 2, 4 \text{ (0 sau 1 sau 2)}$$

- sunt separatoare externe);

$\omega$	0	2	4
$\text{prob}_1(x < \omega)$	$\frac{1}{3}$	$\frac{2}{3}$	$\frac{1}{3}$
$\text{prob}_1(x \geq \omega)$	$\frac{2}{3}$	$\frac{1}{3}$	$\frac{2}{3}$

- secese ponderată minimă de antrenare este  $\varepsilon_1 = \frac{1}{3}$  și se obține punctul  $x_0$ ,  $x \geq 2$  și  $x \leq 4$ ;  
 $\hookrightarrow$  dacă  $x < 0 \Rightarrow h_1 = \text{sign}(0-x) = \underline{\text{sign}(-x)}$ ;
- $d_1 = \frac{1}{2} \ln \frac{1-\varepsilon_1}{\varepsilon_1} = \frac{1}{2} \ln \frac{1-\frac{1}{3}}{\frac{1}{3}} = \frac{1}{2} \ln \frac{\frac{2}{3}}{\frac{1}{3}} =$   
 $= \ln \left( \frac{2}{3} \cdot \frac{3}{1} \right)^{1/2} = \ln \sqrt{2};$
- $\text{mas}(h_1) = \varepsilon_1 = \frac{1}{3}$  (instanta finală este  $x_0$ );
- $D_2(i) = \begin{cases} \frac{D_1(i)}{2\varepsilon_1}, & i \in \{2\}; \\ \frac{D_1(i)}{2(1-\varepsilon_1)}, & i \in \{1; 3\}; \end{cases}$
- $\frac{D_1(i)}{2\varepsilon_1} = \frac{\frac{1}{2}}{\frac{1}{2}} = \frac{1}{2};$
- $\frac{D_1(i)}{2(1-\varepsilon_1)} = \frac{\frac{1}{2}}{2 \cdot \frac{2}{3}} = \frac{1}{2} \cdot \frac{3}{2} \cdot \frac{1}{2} = \frac{3}{8};$
- $\hookrightarrow D_2(i) = \begin{cases} \frac{1}{2}, & i \in \{2\}; \\ \frac{3}{8}, & i \in \{1; 3\}; \end{cases}$

b) m. minim de sterechi în cazul se obține



	0	2	4
$\text{sign}_2(x < 0)$	$\frac{1}{2}$	$\frac{3}{4}$	$\frac{1}{4}$
$\text{sign}_2(x \geq 0)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{3}{4}$

- sezione minima  $\rightarrow$  per banchi la continuazione est.
- $E_2 = \frac{1}{4}$  se si ottiene per tutti  $x \geq 2$ : se  $x \leq 2$ :

$$\hookrightarrow \text{dove } x \geq 2 \Rightarrow f_2 = \frac{\text{sign}(x-2)}{x-2};$$

$$\begin{aligned} D_2 &= \frac{1}{2} \lim_{x \rightarrow 2^+} \frac{1-E_2}{x-E_2} = \frac{1}{2} \lim_{x \rightarrow 2^+} \frac{1-\frac{1}{4}}{x-\frac{1}{4}} = \frac{1}{2} \lim_{x \rightarrow 2^+} \frac{\frac{3}{4}}{x-\frac{1}{4}} = \\ &= \lim_{x \rightarrow 2^+} \left( \frac{3}{4} \cdot \frac{1}{x-1} \right) = \lim_{x \rightarrow 2^+} \frac{3}{4} = \end{aligned}$$

$$D_2(i) = \begin{cases} \frac{D_2(i)}{2-E_2}, & i \in \{3\}; \\ 0, & \text{altri} \end{cases}$$

$$D_2(j) = \begin{cases} \frac{D_2(j)}{2(1-E_2)}, & j \in \{1, 2\}; \\ 0, & \text{altri} \end{cases}$$

$\hookrightarrow$  le istanze classificate sono tutte  $x_3$ ;

$$\frac{D_2(i)}{2-E_2} = \frac{\frac{1}{2}}{2-\frac{1}{4}} = \frac{1}{2} \cdot \frac{3}{4} = \frac{3}{8} = \frac{1}{2};$$

$$\frac{D_2(j)}{2(1-E_2)} = \frac{\frac{1}{4}}{2(1-\frac{1}{4})} = \frac{1}{4} \cdot \frac{1}{2} = \frac{1}{8} = \frac{1}{6};$$

$$\frac{D_2(k)}{2(1-E_2)} = \frac{\frac{1}{3}}{2 \cdot \frac{3}{4}} = \frac{1}{2} \cdot \frac{1}{3} = \frac{1}{6};$$

$$\hookrightarrow D_3(i) = \begin{cases} \frac{1}{2}, & i = 3; \\ \frac{1}{3}, & i = 2; \\ \frac{1}{6}, & i = 1; \end{cases}$$

$D_3$	$x_1$	$x_2$	$x_3$
$\lim \sqrt{x_2}$	-1	-1	-1
$\lim \sqrt{3}$	-1	+1	+1
$H_3(x_i)$	-1	+1	+1

$$\begin{aligned}
 H_2(x_2) &= \text{sign}(\ln \sqrt{2} \cdot (-1) + \ln \sqrt{3} \cdot (+1)) = \\
 &= \text{sign}(-\ln \sqrt{2} + \ln \sqrt{3}) = \\
 &= \text{sign}\left(\ln \frac{\sqrt{3}}{\sqrt{2}}\right) = +1; \\
 &\quad \underbrace{\sqrt{1}}_{>0} \\
 \hookrightarrow \text{errs}(H_2) &= \frac{1}{3};
 \end{aligned}$$

$x$	0	1	2
$\text{err}_3(x)$	$\frac{1}{3}$	$\frac{1}{2}$	$\frac{1}{6}$
$\text{err}_3(x_2)$	$\frac{1}{3}$	$\frac{1}{2}$	$\frac{1}{6}$

- cercare ponderata minimale la entranza

- cercare ponderata minimale la entranza asta  $x \leq 4$ ;

asta  $\epsilon_3 = \frac{1}{6}$  si se obtine punctul  $x \leq 4$ ;

$$\hookrightarrow h_3 = \text{sign}(4-x);$$

$$h_3 = \frac{1}{2} \ln \frac{4-\epsilon_3}{\epsilon_3} = \frac{1}{2} \ln \frac{4-\frac{1}{6}}{\frac{1}{6}} = \frac{1}{2} \ln \frac{23}{6} = \frac{1}{2} \ln \frac{23}{6} =$$


$$= \ln \left( \frac{5}{2} \cdot \frac{15}{1} \right)^{\frac{1}{2}} = \ln \sqrt{15};$$

$x_i$	$x_1$	$x_2$	$x_3$
$\ln \sqrt{2}$	-1	-1	-1
$\ln \sqrt{3}$	-1	+1	+1
$\ln \sqrt{5}$	+1	+1	-1
$H_3(x_i)$	-1	+1	-1

$$\hookrightarrow \text{errs}(H_3) = 0 \Rightarrow \text{punctul } \frac{T=3}{1+1+1},$$

cercare la entranza asta 0;

40



- a) separatau frontieră  $f_1$  ;
- separatoare decisiionale frontieră actuală de date de antrenare sunt  $x = -1$  (separatoare extensie),

	$-1$	$-0,5$	$0,5$
$\text{err}_1(x < -1)$	$\frac{1}{4}$	$\frac{1}{4}$	$\frac{1}{4}$
$\text{err}_1(x \geq -1)$	$\frac{3}{4}$	$\frac{1}{4}$	$\frac{1}{4}$

- $D_1(i) = \frac{1}{4}$ ,  $i = 1, 2$  ;
- aceasta este o soluție minimă la antrenare
- aceeași frontieră se obține pentru  $x = 0,5$  ;
- cite  $\frac{1}{4} = E_1$  și se obține frontieră  $x = 0,5$  ;

$$\underline{f_1 = \text{sign}(-0,5 - x)}$$

b)  $\left\{ E_1; d_1 \right.$ ; acuratețea algoritmul acestui;

$$E_1 = \text{err}_1(x_1 < -0,5) ;$$

$$\underline{E_1 = \frac{1}{4}} ;$$

$$d_1 = \frac{1}{2} \ln \frac{1 - E_1}{E_1} = \frac{1}{2} \ln \frac{1 - \frac{1}{4}}{\frac{1}{4}} = \frac{1}{2} \ln \frac{3}{4} = \frac{1}{2} \ln \frac{3}{4} =$$

$$= \ln \left( \frac{3}{4} \cdot \frac{1}{2} \right) ;$$

$$\underline{d_1 = \ln \frac{3}{4}} ;$$

- acuratețea este  $+ -$  mare;
- se poate să întărească dacă opim
- se poate să întărească dacă opim
- algoritmul cici este  $\leq$  egal cu  $\epsilon_1$  deoarece
- $H_1(x_i)$  este complex deoarece  $b_1$ , adică
- $H_1(x_i) = \text{sign}(d_1 b_1) \Rightarrow \text{sign}(H_1) = \epsilon_1 = \frac{1}{7}$ ;
- $H_1(x_i) = \frac{1}{7} \text{ sign}(d_1 b_1)$  să întărească este

↳ acuratețea la întărească este

$$+ - \text{sign}(H_1) = + - \frac{1}{7} = \frac{6}{7};$$

+ -  $\text{sign}(H_1) = + - \frac{1}{7} = \frac{6}{7};$

c) văzile mălăișă probabilități  $D_2(i)$ :

• instanță clasificată corect este  $x_7$ ;

•  $D_2(i) = \frac{D_1(i)}{2\epsilon_1}, i = 7;$

•  $D_2(i) = \begin{cases} \frac{D_1(i)}{2\epsilon_1}, & i = 7; \\ \frac{D_1(i)}{2(1-\epsilon_1)}, & i \neq 7; \end{cases}$

•  $\frac{D_1(7)}{2\epsilon_1} = \frac{\frac{1}{7}}{2 \cdot \frac{1}{7}} = \frac{1}{14};$

•  $\frac{D_1(i)}{2(1-\epsilon_1)} = \frac{\frac{1}{7}}{2(1-\frac{1}{7})} = \frac{\frac{1}{7}}{2 \cdot \frac{6}{7}} = \frac{1}{12} \cdot \frac{7}{6} = \frac{1}{12};$

↳  $D_2(i) = \begin{cases} \frac{1}{14}, & i = 7; \\ \frac{1}{12}, & i \neq 7; \end{cases}$

d)

$\rightarrow$	-3	-0,5	0,65
$\text{sign}_2(K \rightarrow)$	$\frac{3}{4}$	$\frac{1}{2}$	$\frac{3}{4}$
$\text{sign}_2(K \rightarrow)$	$\frac{1}{4}$	$\frac{1}{2}$	$\frac{1}{4}$

- $\frac{3}{12} + \frac{1}{2} = \frac{1}{4} + \frac{1}{2} = \frac{1+2}{4} = \frac{3}{4}$ ;  $\log_{\frac{3}{4}}(1) = 0$ .
- $\frac{3}{12} + \frac{1}{2} = \frac{3}{4}$ ;
- searcă ponderata minimă la antrenare este  $E_2 = \frac{1}{4}$  și se obține la  $x_2 = -2$ ,  $t_2 = 0,65$ :  
 $\hookrightarrow$  obținem  $x_2 = -2 \Rightarrow h_2 = \text{sign}(x_2)$ ;
- exemplu de antrenare cu ponderile cel mai mic după o doar iteratie;
- instantele de antrenare sunt clasificate sunt  $x_4, x_5, x_6$ ;
- exemplu de antrenare cu ponderile cel mai mic sunt cele corect clasificate;
- $\hookrightarrow x_1, x_2, x_3$  (despre la iteratie anterioare probabilitatea cel mai mic era fostă  $i \neq 7$ );

acuratețea la antrenare pentru iteratie 2:

$$d_2 = \frac{1}{2} \ln \frac{1-E_2}{E_2} = \frac{1}{2} \ln \frac{\frac{1-1}{4}}{\frac{1}{4}} = \frac{1}{2} \ln \frac{0}{\frac{1}{4}} = \frac{1}{2} \ln 0 = 0$$


$$= \ln \left( \frac{3}{4} \cdot \frac{1}{4} \right) = \ln \frac{3}{16}$$

$d_T$	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$
$\ln \frac{3}{4}$	+1	+1	+1	-1	-1	-1	-1
$\ln \frac{3}{16}$	+1	+1	+1	+1	+1	+1	+1
$h_2(x_i)$	+1	+1	+1	-1	-1	-1	-1

(13)

- $H_2(x_4) = \text{sign}(\ln \sqrt{B} \cdot (-1) + \ln \sqrt{B} \cdot (+1)) =$   
 $= \text{sign}(-\ln \sqrt{B} + \ln \sqrt{B}) =$   
 $= \text{sign}\left(\ln \frac{\sqrt{B}}{\sqrt{B} - 1}\right) = \text{sign}\left(\ln \frac{1}{1 - \frac{1}{\sqrt{B}}}\right) = -1;$
- $H_2(x_7) = \text{sign } H_2(x_4); \text{ unbestimmt}$
- accuracy to continuous  $\Leftrightarrow$  m. instanzell  
correct classification dim total  $\Leftrightarrow 1 - \text{err}(H_2);$
- $\text{err}(H_2) = \frac{1}{7};$   
 ↳ accuracy to continuous rate  $1 - \frac{1}{7} = \frac{6}{7}$   
accuracy to emburndate fct  
iteration 1

#### Ex. 4



- a) primul compus de decizie  $\bar{r}_1$ ;
- probabilitatea pe carea  $x_1 \Leftrightarrow \frac{1}{2}$  (extensiv),  $\frac{5}{2}$ ,  $\frac{7}{2}$ ,  $\frac{9}{2}$ ;
  - probabilitatea pe carea  $x_2 \Leftrightarrow \frac{1}{4}$  (extensiv),  $1$ ,  $\frac{7}{4}$ ,  $\frac{5}{4}$ ,  $\frac{7}{2}$ ;
  - $D_1(i) = \frac{1}{g}, i \in \{1, 5\}$ ;

$\Delta$	$-1/2$	$5/2$	$7/2$	$9/2$
$\text{prob}(x_1 < \Delta)$	$\frac{3}{9}$	$\frac{2}{9}$	$\frac{6-3}{9} = \frac{3}{9}$	$\frac{7}{9}$
$\text{prob}_{D_1}(x_2 > \Delta)$	$\frac{4}{9}$	$\frac{1}{9}$	$\frac{1}{3}$	$\frac{2}{9}$

$\Delta$	$1/4$	$1$	$+1/4$	$5/2$	$+1/2$
$\text{prob}_{D_1}(x_1 < \Delta)$	$\frac{5}{9}$	$\frac{6-3}{9} = \frac{3}{9}$	$\frac{5}{9}$	$\frac{6-3}{9} = \frac{3}{9}$	$\frac{5}{9}$
$\text{prob}_{D_1}(x_2 > \Delta)$	$\frac{4}{9}$	$\frac{1}{3}$	$\frac{4}{9}$	$\frac{4}{3}$	$\frac{4}{9}$

- probabilitatea minimă este  $\varepsilon_1 = \frac{4}{9} + \frac{4}{9} = \frac{8}{9}$ ;
- probabilitatea pe carea  $x_1 \geq \frac{5}{2}$ ;
- probabilitatea pe carea  $x_1 \geq \frac{7}{2}$ ;
- $\bar{r}_1 = \text{sign}(\frac{1}{2} - \frac{\Delta}{2})$ ;

- b) probabilitatile instantelor după prima iteratie;
- instantele cu probabilitatea cea mai mare;
- instantele cu probabilitatea cea mai mică;
- probabilitatea creșterii gradă de fi este  $x_6$ ;

- instantă clasificată ca fi este  $x_6$ ;
- $D_2(i) = \begin{cases} D_1(i), & i = 6; \\ 2\varepsilon_1, & i \neq 6; \\ \frac{D_1(i)}{2(1-\varepsilon_1)}, & i \neq 6; \end{cases}$

$$\frac{D_1(6)}{2\varepsilon_1} = \frac{\frac{1}{2}}{2 \cdot \frac{8}{9}} = \frac{1}{8};$$

$$\frac{D_1(i)}{2(1-\varepsilon_1)} = \frac{\frac{1}{2}}{2 \cdot \frac{1}{9}} = \frac{\frac{1}{2}}{\frac{18}{9}} = \frac{1}{2} \cdot \frac{5}{18} = \frac{5}{36};$$

(5)

$$\hookrightarrow D_2(i) = \begin{cases} \frac{1}{2}, & i = 6; \\ \frac{1}{16}, & i \neq 6; \end{cases}$$

$\hookrightarrow$  probabilitatea ca mai multe  
are  $x_0$  (varianta incertă  
clasificate);

c)  $\text{var } D_2(X_1 \leq \frac{5}{2}) = D_2(6) = \frac{1}{2};$

$\hookrightarrow$  măsură probabilitatea de aranjamente produse  
de fișele primei iterări este  $\frac{1}{2}$

(proprietatea  $\text{var } D_{t+1}(h_t) = \frac{1}{2}$ );

$$d) \cdot d_1 = \frac{1}{2} \text{ fm } \frac{1 - E_1}{E_1} = \frac{1}{2} \text{ fm } \frac{1 - \frac{1}{2}}{\frac{1}{2}} = \frac{1}{2} \text{ fm } \frac{1}{\frac{1}{2}} =$$

$$= \ln \left( \frac{2}{3} \cdot \frac{2}{1} \right)^{\frac{1}{2}} = \ln \sqrt{2} = \ln 2^{\frac{1}{2}};$$

$$\text{var}_S(h_1) = E_1 = \frac{1}{2} \quad (H_1 = \text{sign } h_1 d_1);$$

$\Rightarrow$	$\pm 1/2$	$\mp 1/2$	$\mp 1/2$	$\pm 1/2$
$\text{var}_D(X_1 \leq \Rightarrow)$	$\frac{3}{16}$	$\frac{1}{2}$	$\frac{6}{16} = \frac{3}{8}$	$\frac{1}{2}$
$\text{var}_D(X_1 \geq \Rightarrow)$	$\frac{11}{16}$	$\frac{1}{2}$	$\frac{5}{8}$	$\frac{1}{8}$

$$\cdot \frac{3}{16} + \frac{1}{2} + \frac{3}{8} = \frac{6}{16} + \frac{8}{16} = \frac{14}{16} = \frac{7}{8} = \frac{7}{8};$$

$\Rightarrow$	$\pm 1/4$	$\mp 1$	$\mp 1/4$	$\mp 1/2$	$\pm 1/2$
$\text{var}_D(X_2 \leq \Rightarrow)$	$\frac{3}{16}$	$\frac{13}{16}$	$\frac{3}{4}$	$\frac{13}{16}$	$\frac{3}{4}$
$\text{var}_D(X_2 \geq \Rightarrow)$	$\frac{11}{16}$	$\frac{3}{16}$	$\frac{1}{4}$	$\frac{3}{16}$	$\frac{1}{4}$

- se poate folosi metoda minimele la corespunzătoare astăzi
- $\epsilon_2 = \frac{8}{3} \cdot \frac{1}{3}$  și se obține punctul  $x_1 = \frac{3}{2}$ ;
- $\hookrightarrow f_{x_2} = \text{sign}(x_1 - \frac{3}{2})$ ;

(\*) instanță clarificăcăzut de  $H_{2,1}$

$$\begin{aligned} d_1 &= \frac{1}{2} \ln \frac{1-\epsilon_2}{\epsilon_2} = \frac{1}{2} \ln \frac{1-\frac{1}{3}}{\frac{8}{3}} = \frac{1}{2} \ln \frac{2}{8} = \frac{1}{2} \ln \frac{1}{4} = \\ &= \ln \left( \frac{1}{4} \right)^{\frac{1}{2}} = \ln \frac{1}{2}; \end{aligned}$$

	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$
$d_1$	-1	-1	-1	+1	+1	+1	+1	+1	+1
$d_2$	-1	-1	-1	-1	-1	-1	+1	+1	+1
$H_2(x_i)$	-1	-1	-1	+1	+1	+1	+1	+1	+1

$$\begin{aligned} H_2(x_4) &= \text{sign}(d_1 \cdot (+1) + d_2 \cdot (-1)) = \\ &= \text{sign}(\ln \frac{1}{4} - \ln \frac{1}{2}) = \text{sign}(\ln \frac{1}{2}) = \\ &= \text{sign}(\underbrace{\ln \frac{1}{2}}_{>0}) = +1; \end{aligned}$$

$\hookrightarrow x_6$  este clarificăcăzut ( $\text{sign}(H_2) = \frac{1}{3}$ );

a treia iterare;

la clasicăcăzut instanță

$$D_3(i) = \begin{cases} D_2(i), & i \in \{4, 5\}, \\ \frac{2\epsilon_2}{2(1-\epsilon_2)}, & i \notin \{4, 5\}; \end{cases}$$

$$\frac{D_2(i)}{2\epsilon_2} = \frac{\frac{1}{3}}{\frac{1}{3} \cdot \frac{1}{4}} = \frac{1}{4} \cdot 4 = \frac{1}{4};$$



$$\frac{D_2(i)}{2(1-\varepsilon_2)} = \left\{ \begin{array}{l} \frac{1}{2} \\ \frac{1}{2(1-\frac{1}{2})} = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2} \cdot \frac{X^2}{4} = \frac{X^2}{8}; \\ \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{2} \cdot \frac{X}{4} = \frac{1}{8} + \end{array} \right.$$

$$D_3(i) = \frac{1}{4}, i \in \{4; 5\};$$

$$\frac{3}{4}, i = 6;$$

$$\frac{1}{8}, i \in \{4; 5; 6\};$$

	$\frac{1}{2}$	$\frac{5}{2}$	$\frac{7}{2}$	$\frac{9}{2}$
$D_2 D_3(x_1 < 0)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{3}{16}$	$\frac{1}{16}$
$D_2 D_3(x_1 \geq 0)$	$\frac{1}{2}$	$\frac{1}{4}$	$\frac{3}{16}$	$\frac{1}{16}$

$$\frac{1}{4} + \frac{3}{28} = \frac{1}{4} + \frac{3}{28} = \frac{4+3}{28} = \frac{1}{7};$$

$$\frac{3}{28} + \frac{3}{28} = \frac{6}{28} = \frac{3}{14}$$

$$\frac{3}{4} = \frac{1}{2};$$

	$\frac{1}{4}$	$\frac{5}{2}$	$\frac{7}{4}$	$\frac{5}{2}$	$\frac{7}{2}$
$D_2 D_3(x_2 < 0)$	$\frac{1}{2}$	$\frac{25}{28}$	$\frac{1}{4}$	$\frac{25}{28}$	$\frac{1}{4}$
$D_2 D_3(x_2 \geq 0)$	$\frac{1}{2}$	$\frac{3}{28}$	$\frac{1}{4}$	$\frac{3}{28}$	$\frac{1}{4}$

$$\frac{1}{4} + \frac{3}{4} + \frac{3}{28} = \frac{3}{4} + \frac{17}{28} = \frac{21}{28} =$$

$$\frac{1}{4} + \frac{3}{28} + \frac{3}{4} = \frac{3}{4} + \frac{1}{4} + \frac{1}{2} = \frac{8+1+7}{14} = \frac{12}{14} = \frac{6}{7};$$

$$\frac{1}{2} + \frac{3}{4} + \frac{3}{4} + \frac{3}{28} = \frac{14+8+7+2}{28} = \frac{37}{28} = \frac{9}{4};$$

(42)

• Se vor scrie ponderante minime de astfel încât să se obțină punctul  $x_3 = 1$  și  $\frac{x_3 - 3}{2} = \frac{1}{2}$ ;

$$f_3 = \frac{3}{2} \neq \text{se obține punctul } x_3 = 1 \text{ și } \frac{x_3 - 3}{2} = \frac{1}{2};$$


$$\hookrightarrow f_3 = \text{sign}(x_3 - 1) \neq f_3' = \text{sign}\left(x_3 - \frac{3}{2}\right);$$

$$\bullet d_3 = \frac{1}{2} f_3 + \frac{1 - f_3}{2} = \frac{1}{2} f_3 + \frac{1 - \frac{3}{2}}{2} = \frac{1}{2} f_3 - \frac{\frac{3}{2}}{2} = \frac{1}{2} f_3 - \frac{3}{4} =$$

$$= f_3 \left( \frac{25}{25} - \frac{3}{25} \right) + \frac{1}{2} = f_3 \left( \frac{22}{25} \right) + \frac{1}{2} = d_3;$$

	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$	$x_9$
$f_1$	-1	-1	-1	-1	+1	+1	+1	+1	+1
$d_2$	-1	-1	-1	-1	-1	-1	-1	-1	+1
$d_3$	+1	+1	+1	+1	+1	+1	+1	+1	-1
$d_3'$	+1	-1	-1	+1	+1	+1	-1	+1	+1
$H_3(x_i)$	-1	-1	-1	+1	+1	+1	-1	+1	+1
$H_3'(x_i)$	-1	-1	-1	+1	+1	+1	-1	+1	+1

$\hookrightarrow \text{sign}(H_3) = \text{sign}(H_3') = 0$  (f<sub>3</sub> și f<sub>3'</sub> obțin același rezultat d<sub>3</sub> și e<sub>3</sub> și sign(H<sub>3</sub>), deoarece diferența este constantă);




Ex. 5

$$S = \{-2, 2; -2, 0; -0, 3; 0, 1; 0, 2; 0, 4; 0, 1, 6; 1, 7\}$$

(dendrogram) complementare; simple-linkage;

- $x_1 = -2, 2; x_2 = -2; x_3 = -0, 3; x_4 = 0, 1; x_5 = 0, 2; x_6 = 0, 4; x_7 = 1, 6; x_8 = 1, 7; x_9 = 1, 9; x_{10} = 2$



- $d(x_4, x_5) = d(x_7, x_8) = d(x_9, x_{10}) = 0,1$  este distanță minimă  $\Rightarrow C_1 = \{x_4; x_5\}, C_2 = \{x_7; x_8\}, C_3 = \{x_9; x_{10}\}$ ;

$$d(x_1, x_2) = 0,2; d(x_5, x_6) = 0,2;$$

$$d(C_1, x_6) = d(x_5, x_6) = 0,2; d(x_3, x_4) = 0,4;$$

$$d(C_2, C_3) = d(x_8, x_9) = d(x_3, x_4) = 0,4;$$

$$d(x_2, x_5) = d(x_1, x_6) = d(x_3, C_1) = d(x_3, x_4) = 0,2$$

$$d(x_1, x_2) = d(C_1, x_6) = d(C_2, C_3) = 0,2$$

că minimă  $\Rightarrow C_4 = \{x_1; x_2\}, C_5 = \{x_4; x_5; x_6\}$

$$d(C_6) = d(x_7; x_8; x_9; x_{10}) = 1,7;$$

$$d(C_4, x_5) = d(x_2, x_3) = 0,4;$$

$$d(x_3, C_5) = d(x_3, x_4) = 0,4;$$

$$d(x_2, C_6) = d(x_2, x_7) = 1,9;$$

$$d(C_4, C_5) = d(x_2, x_4) = 2,1;$$

$$d(C_4, C_6) = d(x_2, x_7) = 3,6;$$

$$d(C_4, C_6) = d(x_6, x_7) = 1,2;$$

$$d(C_5, C_6) = 0,4$$


că minimă  $\Rightarrow C_7 = \{x_3; x_4; x_5; x_6\}$

~~C<sub>7</sub> = {x<sub>5</sub>; x<sub>6</sub>; x<sub>7</sub>; x<sub>8</sub>}~~

①

②

- $d(c_4, c_7)^{SL} = d(x_2, x_3) = 1,7;$
- $d(c_5, c_7)^{SL} = d(x_3, x_4) = 0,4;$
- $d(c_6, c_7)^{SL} = d(x_6, x_7) = 1,2;$  este cea minima  $\Rightarrow c_7 = c_7 \cup c_6$
- $\hookrightarrow d(c_6, c_7) = 1,2$  este cea minima  $\Rightarrow c_7 = x_7; x_8; x_9; x_{10};$   
 $\Rightarrow c_8 = \{x_2; x_4; x_5; x_6; x_7; x_8; x_9; x_{10}\};$




- ce mai mare distanță dintre 2 clustere este  
 între  $c_7$  și  $c_8 \Rightarrow$  trunchiul dendogramma liniște  
 $c_7$  și  $c_8$  cu o drepte paralele cu axa de  
 condensare;
- $\hookrightarrow \{x_1; x_2\}, \{x_3; x_4; x_5; x_6\}, \{x_7; x_8; x_9; x_{10}\}$

### Ex. 6

$$\left\{ \begin{array}{l} A(-4; -2), B(-3; -2), C(-2; -2), D(-1; -2), E(1; -1), \\ F(1; 1), G(2; 3), H(3; 2), I(3; 4), J(4; 3); \end{array} \right.$$

e) reprezentarea grafică a datelor;



- b) Clustering grafică în manieră bottom-up, cu "single-linkage", distanță euclidiană;
- $\text{SL} \Leftrightarrow d(C_1, C_2) = \min \{d(x, y) | x \in C_1, y \in C_2\}$ ;
  - dacă în o iteratie avem aceeași distanță între 2 cluster, prioritatea la alcătuirea noului cluster este date de ordinea alfabetice;
  - $d(A, B) = d(B, C) = d(C, D) = 1$ ;
  - $d(A, C) = d(B, D) = 2$ ;
  - $d(A, D) = d(H, I) = \sqrt{2}$ ;
  - $d(G, I) = d(H, J) = \sqrt{5}$ ;
  - $d(E, F) = 2$ ;
  - $d(A, B) = d(B, C) = d(C, D) = 1$  este minimă  $\rightarrow C_1 = \{A; B\}, f(C_1) = 1; c(C_1) = 1$
  - $d(A, C) = d(B, D) = 1$  este minimă  $\rightarrow C_2 = \{A; B; C; D\}, f(C_2) = \frac{4+1+2}{3} = 3, c(C_2) = \frac{3}{4} = 0,75$ ;
  - $f(C_2) = \frac{4}{3} = 1,33$ ;  $c(C_2) = \frac{3}{4} = 0,75$ ;

- Este direct propulsional cu media aritmetică a distanțelor dintre punctele din Europa respectiv; cotașa este ~~este~~ ~~convențională~~ medie:
 
$$\hookrightarrow h(c_2) = \frac{d(A,B) + d(B,C) + d(A,C)}{3};$$

$$h^{-1} = \frac{1}{3}(d(A,B) + d(B,C) + d(A,C))$$
- $d(c_2, D) \stackrel{SL}{=} d(C, D) = 1;$   $c_2 = c_2 \cup \{D\},$   
 $\hookrightarrow d(c_2, D)$  este minimă  $\Rightarrow c_3 = \{A, B, C, D\}$ ;  $h(c_3) = \frac{1+1+2+2+1+3}{6} = \frac{10}{6} = 1,67;$   
 $c_3 = \{A, B, C, D\};$   $c(c_3) = \frac{6}{10} = 0,6;$   
 $h(c_3) = \frac{10}{6} = 1,67;$   $d(G, H) = \sqrt{2};$
- $d(c_3, E) \stackrel{SL}{=} d(D, E) = \sqrt{5};$   $d(G, H) = \sqrt{2}$  este minimă =  
 $\hookrightarrow d(G, H) = d(H, i) = \sqrt{2} = 1,414,$   
 $c_4 = \{G, H\}$  și  $h(c_4) = \sqrt{2} = 1,414,$   
 $c_4 = \{G, H\};$   $c(c_4) = \frac{1}{\sqrt{2}} = 0,707;$   
 $c(c_4) = \frac{1}{\sqrt{2}} = 0,707;$
- $d(c_4, i) \stackrel{SL}{=} d(G, i) = \sqrt{2};$
- $d(c_4, j) \stackrel{SL}{=} d(H, j) = \sqrt{2}$  este minimă  $\Rightarrow$   
 $\hookrightarrow d(c_4, i) = d(c_4, j) = \sqrt{2} \Rightarrow h(c_5) = \frac{2\sqrt{2}+2}{3} = 1,667;$   
 $c_5 = c_4 \cup \{i\} = \{G, H, i\};$   $c(c_5) = \frac{3}{2\sqrt{2}+2} = 0,621;$   
 $h(c_5) = 1,667;$
- $d(c_5, j) \stackrel{SL}{=} d(H, j) = \sqrt{2};$
- $d(c_5, f) \stackrel{SL}{=} d(G, f) = \sqrt{5};$
- $d(c_5, f) \stackrel{SL}{=} d(G, f) = \sqrt{5}$  este minimă  $\Rightarrow c_6 = c_5 \cup \{f\},$   
 $\hookrightarrow d(c_5, j) = \sqrt{2}$  este minimă  $\Rightarrow h(c_6) = \frac{4\sqrt{2}+4}{6} = \frac{2\sqrt{2}+2}{3} = 1,667;$   
 $c_6 = \{G, H, i, j, f\};$   $c(c_6) = \frac{3}{2\sqrt{2}+2} = 0,621;$   
 $c(c_6) = \frac{3}{2\sqrt{2}+2} = 0,621;$


- $d(C_3, E) \stackrel{!}{=} d(D, E) = \sqrt{5};$
- $d(C_6, E, F) \stackrel{!}{=} d(G, F) = \sqrt{5};$
- $d(E, F) = 2;$   $\hookrightarrow d(E, F) = 2$  ist minimale  $\Rightarrow C_7 = \{E; F\}$
- $f(C_7) = 2, c(C_7) = \frac{1}{2} = 0,5;$
- $d(C_3, C_7) \stackrel{!}{=} d(D, E) = \sqrt{5};$
- $d(C_6, C_7) \stackrel{!}{=} d(E, F) = \sqrt{5};$  ist minimale
- $\hookrightarrow d(C_3, C_7) = d(C_6, C_7) = \sqrt{5}$  ist minimale
- $\Rightarrow C_8 = C_3 \cup C_7 = \{A; B; C; D; E; F\}$
- $f(C_8) = \frac{10+2+\sqrt{5}+\sqrt{13}+\sqrt{18}+5+\sqrt{21}+\sqrt{26}+\sqrt{17}+\sqrt{10}}{15} = 4,553$

$$f(C_8) = 3,02 \text{ mit } c(C_8) = \frac{15}{45,2996} = 0,331;$$

$$f(C_8) = 4,553, c(C_8) = 0,219;$$

- c)  $C_9 = C_8 \cup C_6$  mit  $f(C_9) = 4,553, c(C_9) = 0,219;$  "complete-linkage":
- $C_1 = \{A; B\}$  mit  $f(C_1) = 1, c(C_1) = 1;$  "complete-linkage"
  - $d(A, B) = d(B, C) = d(C, D) = 1$  ist minimale  $\Rightarrow d(C_1, C_2) = 1$  ist minimale
  - $d(C_1, C) \stackrel{!}{=} d(\#, C) = 2;$   $\hookrightarrow d(C_1, C_2) = 1$  ist minimale  $\Rightarrow C_2 = \{C; D\}$
  - $d(C_1, C_2) = 1$  ist minimale  $\Rightarrow f(C_2) = 1, c(C_2) = 1;$
  - $f(C_2) = 1, c(C_2) = 1, d(i, j) = \sqrt{2};$
  - $d(G, i) = d(G, \#) = 3;$
  - $d(C_1, C_3) \stackrel{!}{=} d(A, \#) = 3;$   $\hookrightarrow d(C_1, C_3) = 3$  ist minimale
  - $d(C_1, C_3) = d(G, i) = d(\#, i) = d(i, j) = \sqrt{2};$   $\hookrightarrow f(C_3) = \sqrt{2},$
  - $d(G, \#) = d(G, i) = d(\#, i) = d(i, j) = \sqrt{2};$   $\hookrightarrow f(C_3) = \sqrt{2},$  ist minimale  $\Rightarrow C_3 = \{G; \#\}$  mit  $f(C_3) = \sqrt{2} = 0,707;$
  - $f(C_3) = 1,414, c(C_3) = \frac{1}{\sqrt{2}} = 0,707;$

- $d(c_3, i) \leq d(H, i) = \sqrt{2} \text{ este minimă} \Rightarrow C_4 = \{i; j\}$
- $d(c_3, j) \leq d(G, j) = 2 \Rightarrow C_4 = \{i; j\}$
- $\hookrightarrow d(i, j) = \sqrt{2} \text{ este minimă} \Rightarrow C_4 = \{i; j\}$   
 $\hookrightarrow f(c_4) = \sqrt{2} = 1,414, c(c_4) = \frac{1}{\sqrt{2}} = 0,707$
- $d(c_3, i) \leq d(G, i) = 2$   
 $\hookrightarrow d(E, F) = d(c_3, i) = 2 \Rightarrow C_5 = \{E; F\}$   
 $f(c_5) = 2, c(c_5) = \frac{1}{2} = 0,5;$
- $d(c_3, c_4) \leq d(c, F) = \sqrt{10};$
- $d(c_3, c_5) \leq d(c, E) = \sqrt{4+7};$
- $d(c_3, c_6) \leq d(G, E) = \sqrt{2+2+4} \Rightarrow C_6 = C_3 \cup C_4,$   
 $\hookrightarrow d(c_3, c_6) = 2 \text{ este minimă} \Rightarrow C_6 = \{G; H; i; j\}$   
 $\hookrightarrow f(c_6) = \frac{(\sqrt{2} + \sqrt{2}) \cdot 2 + 4}{6} = \frac{8}{6} = 1,333$   
 $c(c_6) = \frac{3}{6} = 0,5, f(c_6) = \frac{3\sqrt{2} + 2}{3} = 1,609, c(c_6) = \frac{3}{2\sqrt{2} + 2} = 0,861$   
 $f(c_6) = \frac{3\sqrt{2} + 2}{3} = 1,609, c(c_6) = \frac{3}{2\sqrt{2} + 2} = 0,861$
- $d(c_3, c_6) \leq d(i, E) = \sqrt{2+9};$
- ~~$d(c_1, c_2)$~~   
 $d(c_5, c_6) \leq d(i, E) = \sqrt{2+9} \Rightarrow C_7 = C_1 \cup C_2,$   
 $\hookrightarrow d(c_1, c_2) = 3 \text{ este minimă} \Rightarrow C_7 = \{c\},$   
 $C_7 = \{A; B; C; D\}$   
 $c(c_7) = \frac{6}{10} = 0,6;$
- $d(c_5, c_7) \leq d(A, F) = \sqrt{34};$
- $d(c_5, c_6) \leq d(A, F) = \sqrt{2+9} \text{ este minimă} \Rightarrow C_8 = C_5 \cup C_6,$   
 $\hookrightarrow d(c_5, c_6) = \sqrt{2+9} \text{ este minimă} \Rightarrow f(c_8) = 2,76,$   
 $C_8 = \{G; H; i; j; E; F\}$   
 $c(c_8) = 0,36; f(c_8) = 4,55, c(c_8) = 0,21;$
- $C_9 = C_7 \cup C_8 \text{ și } f(c_9) = 6,31$



**Ex. 2**

$$\left\{ \begin{array}{l} \text{"single-linkage", "average-linkage":} \\ d(X \cup Y, Z) = \frac{1x1d(X, Z) + 1y1d(Y, Z)}{1x1 + 1y1} \end{array} \right.$$

	A	B	C	D	E	F
A	0					
B	0,72	0				
C	0,51	0,25	0			
D	0,84	0,16	0,14	0		
E	0,28	0,77	0,70	0,45	0	
F	0,34	0,61	0,93	0,20	0,67	0

• "single-linkage"  $\leftrightarrow d(c_1, c_2) = \min\{d(A, B)\}$   
 AEC1, BEC2 (SL);

- $d(A, B) = 0,12$  este minimul și  $c_1 = \{A; B\}$ .
- $d(c_1) = 0,12$  (pe frontieră și și AL);
- $d(AB, C) = \min \{d(A, C); d(B, C)\} = 0,25$ ;
- $d(AB, D) = \min \{d(A, D); d(B, D)\} = 0,16$ ;
- $d(AB, E) = \min \{d(A, E); d(B, E)\} = 0,28$ ;
- $d(AB, F) = \min \{d(A, F); d(B, F)\} = 0,34$ ;
- "average-linkage"  $\Leftrightarrow d(c_1, c_2) = \frac{\sum d(A, B)}{|c_1| \cdot |c_2|}$ , unde

- $A \in c_1, B \in c_2$  (AL);
- $d(AB, C) = \frac{d(A, C) + d(B, C)}{2} = \frac{0,51 + 0,25}{2} = 0,38$ ;
  - $d(AB, D) = \frac{d(A, D) + d(B, D)}{2} = \frac{0,84 + 0,16}{2} = \frac{1}{2} = 0,5$ ;
  - $d(AB, E) = \frac{d(A, E) + d(B, E)}{2} = \frac{0,22 + 0,77}{2} = \frac{1,05}{2} = 0,525$ ;
  - $d(AB, F) = \frac{d(A, F) + d(B, F)}{2} = \frac{0,34 + 0,61}{2} = 0,475$ ;

SL	AB	C	D	E	F
AB	0				
C	0,25	0			
D	0,16	0,14	0		
E	0,28	0,70	0,45	0	
F	0,34	0,93	0,20	0,67	0

AL	AB	C	D	E	F
AB	0				
C	0,38	0			
D	0,50	0,14	0		
E	0,525	0,30	0,45	0	
F	0,475	0,93	0,20	0,67	0

- $d(C, D) = 0,14$  este cea minimă și frontieră SL
- $d(c_1, c_2) = 0,14$  este cea minimă și frontieră SL
  - $d(AB, C) = \min \{d(AB, C); d(AB, D)\} = 0,16$ ;
  - $d(AB, D) = \min \{d(AB, D); d(AB, E)\} = 0,16$ ;
  - $d(AB, E) = \min \{d(AB, E); d(AB, F)\} = 0,16$ ;
  - $d(AB, F) = \min \{d(AB, F); d(AB, C)\} = 0,16$ ;
  - $d(CD, E) = \min \{d(CD, E); d(CD, F)\} = 0,20$ ;
  - $d(CD, F) = \min \{d(CD, F); d(CD, C)\} = 0,20$ ;

- $d(AB, CD) = d(AB, \{C \cup D\}) = \frac{2d(AB, C) + 2d(AB, D)}{4} = (0,4) \cdot 6 =$
- $= \frac{d(AB, C) + d(AB, D)}{2} = \frac{0,38 + 0,50}{2} = 0,44; \quad \text{d} = (12) \cdot 4$
- $d(CD, E) = \frac{d(C, E) + d(D, E)}{2} = \frac{0,70 + 0,45}{2} = 0,575;$
- $d(CD, F) = \frac{d(C, F) + d(D, F)}{2} = \frac{0,33 + 0,20}{2} = 0,265;$

AL	AB	CD	E	F
AB	0			
CD	0,44	0		
E	0,575	0,575	0	
F	0,475	0,565	0,67	0

SL	AB	CD	E	F
AB	0			
CD	0,16	0		
E	0,22	0,45	0	
F	0,34	0,20	0,67	0

- $d(AB, CD) = 0,16$  frontne SL  $\Rightarrow d(AB, CD) = 0,44$
- $\frac{\text{frontne AL}}{\text{frontne SL}} \Rightarrow C_3 = \{A; B; C; D\} \Rightarrow f(C_3) = 0,16$
- $\text{frontne SL} \Rightarrow f(C_3) = 0,44$  frontne AL;
- $d(ABCD, E) = \min \{d(AB, E); d(CD, E)\} = 0,22;$
- $d(ABCD, F) = \min \{d(AB, F); d(CD, F)\} = 0,20;$
- $d(ABCD, E) = d(\{A; B\} \cup \{C; D\}, E) =$
- $d(ABCD, E) = d(\{A; B\} \cup \{C; D\}, E) = \frac{2(0,525 + 0,575)}{4} = 0,55;$
- $= \frac{2 \cdot d(AB, E) + 2 \cdot d(CD, E)}{4} = \frac{2(0,525 + 0,575)}{4} = 0,55;$
- $d(ABCD, F) = d(\{A; B\} \cup \{C; D\}, F) =$
- $= \frac{2 \cdot d(AB, F) + 2 \cdot d(CD, F)}{4} = \frac{2(0,475 + 0,565)}{4} = 0,525;$



AL	ABCD	E	F
ABCD	0		
E	0,55	0	
F	0,52	0,67	0

SL	ABCFD	E	F
ABCFD	0		
E	0,23	0	
F	0,20	0,67	0

- $d(ABCFD, F) = 0,52$  function AL  $\Rightarrow d(ABCFD, F) = 0,20$   
function SL went missing  $\Rightarrow C_4 = \{A; B; C; D; F\}$   
 $f(C_4) = 0,20$  (SL),  $f(C_4) = 0,52$  (AL);
- $d(ABCFD, E) = \min\{d(ABCFD, E); d(ABCFD, F)\} = 0,23$ ;
- $d(ABCFD, E) = d(\{A; B; C; D\} \cup \{F\}, E) =$
- $d(ABCFD, E) = \frac{4 \cdot 0,55 + 0,67}{5} = 0,574;$   
 $= 4d(ABCFD, E) + d(F, E) = \frac{4 \cdot 0,55 + 0,67}{5} = 0,574;$


SL	ABCFD	E
ABCFD	0	
E	0,28	0

AL	ABCFD	E
ABCFD	0	
E	0,574	0



Ex. 9

$\{A(-1; 0), B(1; 0), C(0; 1), D(3; 0), E(3; 1)\}$ ; 2-means;  $\mu_1(-1; 0)$ ,  $\mu_2(3; 1)$ ; 2 clusters



- $C_1 = \{A; B; C\}$ ,  $C_2 = \{E; D\}$ ;

- $x_{\mu_1} = \frac{x_A + x_B + x_C}{3} = \frac{-1 + 1 + 0}{3} = 0$ ;


- $y_{\mu_1} = \frac{y_A + y_B + y_C}{3} = \frac{0 + 0 + 1}{3} = \frac{1}{3}$ ;

$\hookrightarrow \mu_1(0; \frac{1}{3})$ ;

- $x_{\mu_2} = \frac{x_E + x_D}{2} = \frac{3+3}{2} = \frac{6}{2} = 3$ ;

- $y_{\mu_2} = \frac{y_E + y_D}{2} = \frac{0+1}{2} = \frac{1}{2}$ ;

$\hookrightarrow \mu_2(3; \frac{1}{2})$ ;




$$\hookrightarrow C_1 = \{A; B; C\} \text{ și } C_2 = \{D; E\};$$

Ex. 10

$\left\{ \begin{array}{l} A(2; 4), B(2; 5), C(3; 4), D(5; 3), E(7; 5), F(6; 4); \\ G(1; 2), H(4; 3); 3\text{-meanii}; M_1 = A, M_2 = D; \\ M_3 = G; \text{ distanță succidantă} \\ \text{față de iteratii} \end{array} \right.$

a)



(31)


$\hookrightarrow C_1 = \{A\}, C_2 = \{C; D; E; F\}, C_3 = \{G; B\}$

b) m. iteratie pentru caa algoritmul converge;

- $C_1 = \{A\} \Rightarrow \mu_1 = 1;$
- $\mu_{H2} = \frac{x_C + x_D + x_E + x_F + x_H}{5} = \frac{8+5+7+6+4}{5} = \frac{30}{5} = 6;$
- $\mu_{H2} = \frac{y_C + y_D + y_E + y_F + y_H}{5} = \frac{4+8+5+4+9}{5} = \frac{30}{5} = 6;$

$\hookrightarrow \mu_2(6; 6);$

- $\mu_{H3} = \frac{x_G + x_B}{2} = \frac{2+1}{2} = \frac{3}{2}; \quad \left. \begin{array}{l} \mu_3(\frac{3}{2}; \frac{7}{2}) \\ \end{array} \right\}$
- $\mu_{B3} = \frac{y_G + y_B}{2} = \frac{5+2}{2} = \frac{7}{2};$



$\hookrightarrow C_1 = \{A; H\}, C_2 = \{C; D; E; F\}, C_3 = \{G; B\};$

$\hookrightarrow$  pentru a doua iteratie;

## EXERCITII SESIUNE

### Ex. 1

demonstratie  $\log \mathcal{P}(x|\theta) \geq \sum_{\#} g(\#) \log \left( \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right)$ ;

- $\log$  ca baza exponentială  $\Leftrightarrow$  funcție concavă (1);
- inegalitatea lui Jensen  $\Leftrightarrow$  considerând  $x = \#$
- inegalitatea abatare (varianță), dacă  $f$  este o variabilă concavă, atunci  $f(E[x]) \geq E[f(x)]$  (2);
- funcție concavă, atunci  $\log(E[x]) \geq E[\log(x)]$  (3);
- (1), (2)  $\Rightarrow \log(E[x]) \geq \log \left( \sum_{\#} \mathcal{P}(x,\#|\theta) \right) =$
- $I(\theta) = \log \mathcal{P}(x|\theta) = \log \left( \sum_{\#} \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right) = \log \left( E_{g(\#)} \left[ \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right] \right)$  (4)
- $= \log \left( \sum_{\#} g(\#) \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right) = \log \left( E_{g(\#)} \left[ \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right] \right) \geq$
- din (3),  $x \rightarrow \frac{\mathcal{P}(x,\#|\theta)}{g(\#)}$   $\Rightarrow \log \left( E_{g(\#)} \left[ \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right] \right) \geq$  ;  $I(\theta) = \log \mathcal{P}(x|\theta)$ ;
- $\geq E_{g(\#)} \left[ \log \left( \frac{\mathcal{P}(x,\#|\theta)}{g(\#)} \right) \right]$  (5);
- (3), (5)  $\Rightarrow I(\theta) \geq \sum_{\#} g(\#) \log \frac{\mathcal{P}(x,\#|\theta)}{g(\#)}$
- $\hookrightarrow$  aderentat;

### Ex. 2

- demonstratie  $\log \mathcal{P}(x|\theta) = H(g(\#), \theta) + KL(g(\#) // \mathcal{P}(\#|x, \theta))$ ;
- $H(g(\#), \theta) = \sum_{\#} g(\#) \log \left( \frac{\mathcal{P}(\#|x, \theta)}{g(\#)} \right)$  (6);
  - $= \sum_{\#} g(\#) \log \left( \frac{\mathcal{P}(\#|A) \cdot \mathcal{P}(x|\theta)}{g(\#)} \right)$  (7);
  - $\hookrightarrow \mathcal{P}(\#|A) = \mathcal{P}(B|A) \cdot \mathcal{P}(C|A, B) \Leftrightarrow$
  - $\mathcal{P}(\#|x, \theta) = \mathcal{P}(x|\theta) \cdot \mathcal{P}(\#|x, \theta)$ ;
  - $\log a \cdot b = \log a + \log b$  (8);
  - $\log a \cdot b = \log a + \log b$  (8);

- (4), (5)  $\Rightarrow H(g(\#), \theta) = \sum_{\#} g(\#) \left( \log \frac{g(\#|x, \theta)}{g(\#)} + \log \bar{P}(x|\theta) \right) = \sum_{\#} \left( \frac{g(\#)}{g(\#)} \log \frac{g(\#|x, \theta)}{g(\#)} + g(\#) \log \bar{P}(x|\theta) \right) \quad (3);$
  - $\sum_{\#} a + \sum_{\#} b = \sum_{\#} (a+b) \quad (4);$
  - (3), (4)  $\Rightarrow H(g(\#), \theta) = \sum_{\#} g(\#) \log \frac{g(\#|x, \theta)}{g(\#)} + \sum_{\#} g(\#) \log \bar{P}(x|\theta) = \sum_{\#} g(\#) \log \frac{g(\#|x, \theta)}{g(\#)} + \sum_{\#} g(\#) \log \frac{\bar{P}(x|\theta)}{g(\#)} \quad (5);$
  - $\sum_{\#} g(\#) \log \frac{g(\#|x, \theta)}{g(\#)} + \sum_{\#} g(\#) \log \frac{\bar{P}(x|\theta)}{g(\#)} + \bar{P}(x|\theta) \sum_{\#} g(\#) = \sum_{\#} g(\#) \log \frac{g(\#|x, \theta)}{g(\#)} + -\sum_{\#} g(\#) \log \frac{g(\#|x, \theta)}{g(\#)} = -KL(g(\#) // \bar{P}(x|\theta)) \quad (6)$
  - $KL(g(\#) // \bar{P}(x|\theta)) = -KL(g(\#) // \bar{P}(x|\theta)) \Rightarrow$   
 $\sum_{\#} g(\#) \log \frac{g(\#|x, \theta)}{g(\#)}$  este o distribuție de probabilitate dintr-o  
distribuție de probabilități de probabilitate dintr-o
  - $\sum_{\#} g(\#) = 1$  (suma probabilităților de probabilitate este 1)  $\Rightarrow$   
 $H(g(\#), \theta) \Leftrightarrow H(g(\#), \theta) = -KL(g(\#) // \bar{P}(x|\theta))$  +  
 $+ \log \bar{P}(x|\theta) \cdot 1;$   
 $H(g(\#), \theta) = \log \bar{P}(x|\theta) - KL(g(\#) // \bar{P}(x|\theta));$   
 $\log \bar{P}(x|\theta) = H(g(\#), \theta) + KL(g(\#) // \bar{P}(x|\theta));$   
 $\hookrightarrow$  adevărat;  
 $\hookrightarrow$   $g(\#)$  este

Ex.3 demonstratie maximul lui  $\hat{\theta}$  în raport cu  $g(\hat{x})$  este atins folosind distribuția  $P(\hat{x} | x, \theta(t))$  și valoarea

### Ex. 3

- maximum este  $\max_{g(x)} I(g(x), \theta(t)) = H(\bar{P}(x|\theta(t)))$ .
- $+ E_{\bar{P}(x|\theta(t))} [\log \bar{P}(x, \theta(t))]$ ;
- din Ex. 1  $\Rightarrow I(g(x), \theta) \leq \log \bar{P}(x|\theta)$ ;  
 $\hookrightarrow I(g(x), \theta(t)) \leq \log \bar{P}(x|\theta(t))$  (4);  
 $\hookrightarrow I(g(x), \theta(t)) = I(g(x), \theta) + KL(g(x) || \bar{P}(x|\theta(t)))$ ;
  - din Ex. 2  $\Rightarrow \log \bar{P}(x|\theta(t)) - I(g(x), \theta(t)) = 0 \Leftrightarrow \frac{\partial}{\partial t} I(g(x), \theta(t)) = 0$  (4);  
 $\hookrightarrow \log \bar{P}(x|\theta(t)) = I(g(x), \theta(t)) + KL(g(x) || \bar{P}(x|\theta(t)))$ ;
  - $\exists KL(\pi || \mu) = 0 \quad (KL(\pi || \mu) = 0 \Leftrightarrow \pi = \mu)$  (3);  
 $\Rightarrow I(g(x), \theta(t)) = I(g(x), \theta(t)) + KL(g(x) || \bar{P}(x|\theta(t)))$ ;
  - (2), (3), (4)  $\Rightarrow \bar{P}(x|t, \theta(t)) = \log \bar{P}(x|\theta(t)) + I(g(x), \theta(t)) + 0$ ;  
 $\log \bar{P}(x|\theta(t)) = I(g(x), \theta(t))$  (4);  
 $\log \bar{P}(x|\theta(t)) = I(g(x), \theta(t))$  (4);  
 $\log \bar{P}(x|\theta(t)) = \max_{g(x)} I(g(x), \theta(t))$  se obtine.
- functie distributie  $g(x) = \max_{g(x)} I(g(x), \theta(t))$  (5).
- $\log \bar{P}(x|\theta(t)) = \max_{g(x)} I(g(x), \theta(t))$  =  
 $\stackrel{(5)}{=} I(\bar{P}(x|t, \theta(t)), \theta(t)) =$   
 $= \sum_x \bar{P}(x|t, \theta(t)) \log \left( \frac{\bar{P}(x, \theta(t))}{\bar{P}(x|t, \theta(t))} \right)$  (6);  
 $= E_{\bar{P}(x|t, \theta(t))} [\log \bar{P}(x|t, \theta(t))]$  (7);
  - $\log b^a = \log a - \log b$  (8);
  - (6), (7)  $\Rightarrow \max_{g(x)} I(g(x), \theta(t)) =$   
 $= E_{\bar{P}(x|t, \theta(t))} [\log \bar{P}(x, \theta(t)) - \log \bar{P}(x|t, \theta(t))] \quad (8)$ ;

- $E[x-y] = E[x] - E[y]$  (3);
- $(2), (3) \Rightarrow \max_{\theta(t)} P(\theta(t), \theta(t)) =$
- $= E_{\theta(\cdot|x, \theta(t))} [\log P(x, \theta(t))] - E_{\theta(\cdot|x, \theta(t))} [\log P(x, \theta(t))];$
- $= E_{\theta(\cdot|x, \theta(t))} [\log P(x, \theta(t))] - H[\theta(\cdot|x, \theta(t))];$

$\hookrightarrow$  aderent;

### Ex. 4

- demonstratie  $\log P(x|\theta) - \log P(x|\theta(t)) \geq \theta(t|\theta(t)) - \theta(\theta(t)|\theta(t))$ , și fixat  $\theta$  este corect
- $\theta(\theta|\theta(t)) \geq \theta(\theta|A) \cdot \theta(A|\theta(t))$ ;  ~~$\log a - \log b \geq \log a - \log c$~~
- $\theta(\theta|A) = \theta(\theta|A) \cdot \theta(A|x, \theta)$ ;
- $\theta(x, \theta|x) \leq \theta(x|\theta) \cdot \theta(\theta|x, \theta)$ ;
- $\log \theta(x, \theta|x) = \log \theta(x|\theta) + \log \theta(\theta|x, \theta)$ ;
- $\log \theta(x, \theta|x) \leq \log \theta(x|\theta) - \log \theta(\theta|x, \theta)$ ;
- $\log \theta(x|\theta) = \sum_{\theta} (\log \theta(\theta|x, \theta)) - \sum_{\theta} (\log \theta(\theta|x, \theta)) \cdot \theta(\theta|x, \theta(t))$  (3);
- $\sum_{\theta} \theta(\theta|x, \theta(t)) \cdot \theta(\theta|x, \theta(t)) \geq \sum_{\theta} \theta(\theta|x, \theta(t))$  (4);
- $\sum_{\theta} \theta - b = \sum_i a_i - \sum_i b_i$  (2);
- $\log a \cdot b = \log a + \log b$  (2);
- $a = b - c \Rightarrow a = b - c$   $\Rightarrow \sum_i a_i = \sum_i b_i - \sum_i c_i = (b - c) = (3)$ ;
- (3), (4)  $\Rightarrow \sum_{\theta} \theta(\theta|x, \theta(t)) \log \theta(x|\theta) =$

$$\begin{aligned}
&= \sum_{\theta} (\mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) - \mathbb{P}(x|\theta)) \\
&\quad \cdot \log \mathbb{P}(x|\theta)) \stackrel{(4)}{=} ; \\
\sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) &= \sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) - \\
&\quad - \sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) \stackrel{(5)}{=} ; \\
-\sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) &= \log \mathbb{P}(x|\theta) \sum_{\theta} \mathbb{P}(x|\theta) = \\
\sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) &= \log \mathbb{P}(x|\theta) \stackrel{(6)}{=} ; \\
\bullet \sum_{\theta} \mathbb{P}(x|\theta) \cdot 1 &= \log \mathbb{P}(x|\theta) \stackrel{(6)}{=} ; \\
\mathbb{P}(x) = \mathbb{P}(x|\theta) &\text{ este o distribuție de} \\
\text{probabilitate} \Rightarrow \sum_{\theta} \mathbb{P}(x) &= 1 ; \\
\mathbb{P}(x|\theta) = \mathbb{E}_{\theta}(\mathbb{P}(x|\theta)) \left[ \log \mathbb{P}(x|\theta) \right] &= \\
\bullet \mathbb{H}(\theta|\theta(t)) &= \sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) \stackrel{(7)}{=} ; \\
\mathbb{H}(\theta, \theta(t)) &= -\sum_{\theta} \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) \log \mathbb{P}(x|\theta) \Leftrightarrow \\
\text{cross-entropie } (\theta); & \\
(\theta), (6), (7), (8) \Rightarrow \log \mathbb{P}(x|\theta) = \theta(\theta|\theta(t)) + C(\theta|\theta(t)), & \\
\bullet \mathbb{H}(\theta) &= \log \mathbb{P}(x|\theta) \stackrel{(9)}{=} ; \\
\bullet (\theta), \theta = \theta(t) &+ C(\theta|\theta(t)) \stackrel{(10)}{=} ; \\
+ C(\theta|\theta(t)) \Leftrightarrow C(\theta|\theta(t)) \geq C(\theta|\theta(t)) \stackrel{(11)}{=} ; \\
\bullet \text{inegalitatea lui Gibbs} \Leftrightarrow C(\theta|\theta(t)) = & \\
\bullet (\theta) - (10) \Rightarrow \log \mathbb{P}(x|\theta) - \log \mathbb{P}(x|\theta(t)) = & \\
- \theta(\theta|\theta(t)) - \theta(\theta|\theta(t)) + C(\theta|\theta(t)) - C(\theta|\theta(t)) \stackrel{(12)}{=} ; \\
\bullet (11), (12) \Rightarrow \log \mathbb{P}(x|\theta) - \log \mathbb{P}(x|\theta(t)) \geq & \\
\geq \theta(\theta|\theta(t)) - \theta(\theta|\theta(t)) ; \\
\hookrightarrow \underline{\text{adevărat}} ;
\end{aligned}$$

Ex. 5

2 monede; frunză cu probabilitate  $\pi$  (probabilă);  
frunză cu probabilitate  $1 - \pi$  (a două);

în acumulare;

frentă fiericătățe, alegeră prima monedă  
cu probabilitate  $\pi$ ;

rezultatul fiericătăței acumulare i este  $x_i \in \{0, 1\}$ ;

$$\theta = \{\pi, 1 - \pi\},$$

$x_i \in \{0, 1\}$  este moneda fiericătățe furentă acumulare i;

$$P(x_i | \pi, \theta) = P(x_i = 1 | \pi, \theta);$$

$$P(x_i | \pi, \theta) = \sum_{x_i \in \{0, 1\}} x_i \cdot P(x_i | \pi, \theta) =$$

$$\bullet P(x_i | \pi, \theta) = 0 \cdot P(x_i = 0 | \pi, \theta) + 1 \cdot P(x_i = 1 | \pi, \theta);$$

$$= 0 \cdot P(x_i = 0 | \pi, \theta)$$

$$\hookrightarrow P(x_i | \pi, \theta) = P(x_i = 1 | \pi, \theta);$$

$$b) P(x_i = 1 | \pi, \theta(t)) \text{ cu Bayes; } P(A|B)P(B) / [P(A|B)P(B) + P(\bar{A}|B)P(\bar{B})] \quad (1)$$

• teorema lui Bayes  $\Leftrightarrow P(B|A) = \frac{P(A|B)P(B)}{P(A|B)P(B) + P(\bar{A}|B)P(\bar{B})}$

$$\cancel{P(x_i | \pi, \theta(t)) = P(x_i = 1 | \pi, \theta(t))}$$

$$\cancel{P(x_i | \pi, \theta(t)) = P(x_i = 1 | \pi, \theta(t))}$$

$$\cancel{P(x_i | \pi, \theta(t)) = P(x_i = 1 | \pi, \theta(t))}$$

$$\cancel{P(x_i | \pi, \theta(t)) = P(x_i = 1 | \pi, \theta(t))}$$

$$\cancel{P(x_i | \pi, \theta(t)) = P(x_i = 1 | \pi, \theta(t))}$$

$$\begin{aligned}
 & \bullet P(\hat{x}_i = 1 | x_i, \theta(t)) = \\
 & = \frac{P(x_i | \hat{x}_i = 1, \theta(t)) P(\hat{x}_i = 1 | \theta(t))}{P(x_i | \hat{x}_i = 1, \theta(t)) P(\hat{x}_i = 1 | \theta(t)) + P(x_i | \hat{x}_i = 0, \theta(t)) P(\hat{x}_i = 0 | \theta(t))} \\
 & = \frac{q^{x_i} \cdot (1-q)^{1-x_i}}{q^{x_i} \cdot (1-q)^{x_i} + q^{1-x_i} \cdot (1-q)^{1-x_i}} ; \\
 & \hookrightarrow P(\hat{x}_i = 1 | x_i, \theta(t)) = \frac{q^{x_i} (1-q)^{1-x_i}}{q^{x_i} (1-q)^{x_i} + q^{1-x_i} (1-q)^{1-x_i}} ;
 \end{aligned}$$

c)  $\log P(x, z | \theta)$ :

$$\begin{aligned}
 & \bullet \log P(x, z | \theta) = \log \prod_{i=1}^n P(x_i, z_i | \theta) = \\
 & = \log \prod_{i=1}^n P(x_i | \theta) \cdot P(z_i | x_i, \theta) = \\
 & \hookrightarrow P(B \cap C | A) = P(B|A) \cdot P(C|A, B), \\
 & = \log \prod_{i=1}^n P(x_i | \theta) \cdot P(z_i | x_i, \theta) = \\
 & = \log \prod_{i=1}^n \log \left( q^{x_i} \cdot (1-q)^{1-x_i} \cdot q^{z_i} \cdot (1-q)^{1-z_i} \right) = \\
 & = \sum_{i=1}^n \log \left( q^{x_i} \cdot (1-q)^{1-x_i} \cdot q^{z_i} \cdot (1-q)^{1-z_i} \right) = \\
 & \hookrightarrow \log a \cdot b = \log a + \log b ; \\
 & = \sum_{i=1}^n \left( \log q^{x_i} \cdot (1-q)^{1-x_i} + \log q^{z_i} \cdot (1-q)^{1-z_i} \right) = \\
 & \bullet \log q^x = x \log q ; \\
 & \hookrightarrow \log P(x, z | \theta) = \sum_{i=1}^n \left( x_i \log q^{x_i} (1-q)^{1-x_i} + \right. \\
 & \quad \left. + (1-x_i) \log q^{1-x_i} (1-q)^{x_i} \right) ;
 \end{aligned}$$

d)  $Q(\theta | \theta(t)) = E_{\pi(x_i | x, \theta(t))} [\log \pi(x_i | \theta)] =$

 $= \sum_{i=1}^n E[x_i | x_i, \theta(t)] (\log \pi + x_i \log \pi + (1-x_i) \log(1-\pi) +$ 
 $+ (1 - E[x_i | x_i, \theta(t)]) (\log(1-\pi) + x_i \log \pi +$ 
 $+ (1-x_i) \log(1-\pi));$ 
 $Q(\theta | \theta(t)) = E_{\pi(x | x, \theta(t))} [\log \pi(x | \theta)] =$ 
 $= E_{\pi(x | x, \theta(t))} \left[ \sum_{i=1}^n (x_i \log \pi + (1-\pi)x_i \log(1-\pi) + (1-x_i)) \right] =$ 
 $= \sum_{i=1}^n (E[x_i | x_i, \theta(t)] \log x_i + (1-x_i) \log(1-\pi)) =$ 
 $+ (1 - E[x_i | x_i, \theta(t)]) \log x_i + (1-x_i) \log(1-\pi) =$ 
 $= \sum_{i=1}^n (E[x_i | x_i, \theta(t)] \log x_i + (1-x_i) \log(1-\pi) +$ 
 $+ \log x_i + (1-x_i) \log(1-\pi) + E[x_i | x_i, \theta(t)] \log x_i +$ 
 $+ \log x_i + (1-x_i) \log(1-\pi) + \log x_i + (1-x_i) \log(1-\pi)) =$ 
 $= \sum_{i=1}^n (E[x_i | x_i, \theta(t)] + \log x_i + (1-x_i) \log(1-\pi)) +$ 
 $+ \log x_i + (1-x_i) \log(1-\pi) + \log x_i + (1-x_i) \log(1-\pi) +$ 
 $+ \log x_i + (1-x_i) \log(1-\pi) + \log x_i + \log(1-\pi) +$ 
 $+ \log x_i + \log(1-\pi) + \log x_i + \log(1-\pi) +$ 
 $+ \log x_i + \log(1-\pi);$ 
 $\log a \cdot b = \log a + \log b;$ 
 $\log a + \log b = \log(a+b);$

$$\begin{aligned} & \hookrightarrow \log a \cdot b = \log a + \log b \\ \bullet & \log a^m = m \log a \quad (\text{1}) \\ \bullet & Q(\theta, \theta(t)) \leq \sum_{i=1}^n E[\xi_i | x_i, \theta(t)] (\log \pi + (1-\pi) \log (1-\pi)) \\ & + \log \pi + x_i \log \pi + (1-x_i) \log (1-\pi) + \log (1-\pi') + \end{aligned}$$

$$\begin{aligned}
 & + x_i \log 2 + (1-x_i) \log (1-2) + \log (1-\bar{x}) ; \\
 \hookrightarrow Q(\theta, \delta^{(t)}) = & \sum_{i=1}^n \left( E[z_i | x_i, \delta^{(t)}] \right) (x_i \log p + \right. \\
 & \left. + (1-x_i) \log (1-p) + \log \bar{x} \right) + (1 - E[z_i | x_i, \delta^{(t)}]) \cdot \\
 & \cdot (\log 2 \cdot x_i + (1-x_i) \log (1-2) + \log (1-\bar{x})) ;
 \end{aligned}$$

Ex. 6

$x_i$	$x_i$	$x_i$	$y_i$
$x_1$	1	2	+1
$x_2$	2	3	+1
$x_3$	3	4	-1
$x_4$	3	2	-1
$x_5$	3	1	-1
$x_6$	4	4	-1
$x_7$	5	4	-1
$x_8$	5	2	+1
$x_9$	5	1	+1

$T=3$  iteratii AdaBoost;

- $T=1 \rightarrow D_1(i) = \frac{1}{9}, \forall i=1, 9;$
- pozitiv extinsa  $\Leftrightarrow \frac{1}{2}$  puncte  $x_1$  si  $x_2$ ;
- pozitiv intinsa  $\Leftrightarrow \frac{5}{2}$  si  $\frac{3}{2}$  puncte  $x_1$  si  $x_2$ ;
- $\frac{3}{2}, \frac{5}{2}$  si  $\frac{7}{2}$  puncte  $x_3$ ;

• cercana poliedră mică care în conținutul său

$$E_3 = \frac{1}{8} \cdot \frac{\pi}{4} \text{ se obține, pentru } x_1 = \frac{3}{2};$$

$$\rightarrow h_3 = \arcsin\left(x_1 - \frac{3}{2}\right);$$

$$\frac{1}{8} \cdot \frac{\pi}{4} = \frac{1}{8} \cdot \frac{\pi}{4} = \frac{1}{32} \cdot \frac{\pi}{4} =$$

$$\bullet d_3 = \frac{1}{2} \ln \frac{1-E_3}{E_3} = \frac{1}{2} \ln \frac{1-\frac{1}{32}}{\frac{1}{32}} = \frac{1}{2} \ln \frac{31}{1} =$$

$$= \frac{1}{2} \ln \frac{\pi}{8} \cdot \frac{8}{\pi} = \frac{1}{2} \ln 1 = \ln \sqrt{1};$$

$t$	$E_t$	$dt$	$Dt(1)$	$Dt(2)$	$Dt(3)$	$Dt(4)$	$Dt(5)$	$Dt(6)$	$Dt(7)$
1	$\frac{3}{4}$	$\ln \sqrt{2}$	1/8	1/8	1/8	1/8	1/8	1/8	1/8
2	$\frac{2}{3}$	$\ln \sqrt{3}$	1/4	1/4	1/4	1/4	1/4	1/4	1/4
3	$\frac{1}{2}$	$\ln \sqrt{4}$	1/24	1/24	1/24	1/24	1/24	1/24	1/24

$t$	$E_t$	$dt$	$Dt(8)$	$Dt(9)$	$Dt(10)$	$Dt(11)$
4	$\frac{0}{2}$	$\ln \sqrt{2}$	1/8	1/8	1/8	1/8
5	$\frac{0}{3}$	$\ln \sqrt{3}$	1/4	1/4	1/4	1/4
6	$\frac{0}{4}$	$\ln \sqrt{4}$	1/24	1/24	1/24	1/24

$t$	$dt$	$x_1$	$x_2$	$x_3$	$x_4$	$x_5$	$x_6$	$x_7$	$x_8$
1	$\ln \sqrt{2}$	+1	+1	-1	+1	+1	-1	-1	+1
2	$\ln \sqrt{3}$	+1	+1	-1	-1	-1	-1	-1	-1
3	$\ln \sqrt{4}$	-1	-1	-1	-1	-1	-1	+1	+1
-	$h_3(x_i)$	+1	+1	-1	-1	-1	-1	-1	+1

Ex. 7  $A(-1, -2), B(-3, -2), C(-2, -2), D(-1, -2), E(1, -1);$


$F(1, 1), G(2, 3), H(3, 2), I(3, 4), J(4, 3);$

metricele lui Ward;

distanța dintre 2 perchi de clustere este egală  $\Leftrightarrow$

distanța dintre 2 perchi de clustere este egală  $\Leftrightarrow$

prioritate alfabetice;



- $\Delta(\{AB\}, \{B\}) = \frac{1+1}{1+1} \|\mu_{\{AB\}} - \mu_{\{B\}}\|^2 ;$
- $\mu_{\{AB\}} = \frac{1}{4} \cdot \begin{pmatrix} -4 \\ -2 \end{pmatrix} = \begin{pmatrix} -1 \\ -1 \end{pmatrix} ;$
- $\mu_{\{B\}} = \frac{1}{1} \cdot \begin{pmatrix} -3 \\ -2 \end{pmatrix} = \begin{pmatrix} -3 \\ -2 \end{pmatrix} ;$
- $\|\mu_{\{AB\}} - \mu_{\{B\}}\|^2 = \sqrt{(-4+3)^2 + (-2+2)^2} = \sqrt{1^2 + 0^2} = 1 ;$
- $\Delta(\{AB\}, \{B\}) = \frac{1}{2} \cdot 1 = \frac{1}{2} ;$
- $\Delta(\{AB\}, \{E\}) = \frac{1+1}{1+2} \|\mu_{\{AB\}} - \mu_{\{E\}}\|^2 =$   
 $= \frac{1}{2} \left\| \frac{1}{4} \cdot \begin{pmatrix} -4 \\ -2 \end{pmatrix} - \frac{1}{1} \cdot \begin{pmatrix} 1 \\ -2 \end{pmatrix} \right\|^2 = \frac{1}{2} \left\| \begin{pmatrix} -1 \\ -1 \end{pmatrix} - \begin{pmatrix} 1 \\ -2 \end{pmatrix} \right\|^2 =$   
 $= \frac{1}{2} \left( (-1-1)^2 + (-1+2)^2 \right) \cdot \frac{1}{2} = \frac{1}{2} (2^2 + 1^2) \cdot \frac{1}{2} = \frac{5}{4} = \frac{5}{2} ;$
- $\Delta(\{E\}, \{F\}) = \frac{1+1}{1+2} \|\mu_{\{E\}} - \mu_{\{F\}}\|^2 =$   
 $= \frac{1}{2} \left\| \frac{1}{1} \cdot \begin{pmatrix} 1 \\ -2 \end{pmatrix} - \frac{1}{2} \cdot \begin{pmatrix} 2 \\ -1 \end{pmatrix} \right\|^2 = \frac{1}{2} \left\| \begin{pmatrix} 1 \\ -2 \end{pmatrix} - \begin{pmatrix} 1 \\ -1 \end{pmatrix} \right\|^2 =$   
 $= \frac{1}{2} ((1-1)^2 + (-2+1)^2) = \frac{1}{2} (0^2 + 1^2) = \frac{1}{2} = \frac{1}{2} ;$
- $\Delta(\{B\}, \{C\}) = \Delta(\{C\}, \{D\}) = \Delta(\{A\}, \{B\}) = \frac{1}{2} ;$

(15)

- $\Delta(\{F\}, \{G\}) = \frac{1 \cdot 1}{1+1} \|M_{FG} - M_{FGF}\|^2 =$   
 $= \frac{1}{2} \left\| \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 2 \\ 3 \end{pmatrix} \right\|^2 = \frac{1}{2} \left\| \begin{pmatrix} 1 \\ 1 \end{pmatrix} - \begin{pmatrix} 2 \\ 3 \end{pmatrix} \right\|^2 =$   
 $= \frac{1}{2} ((1-2)^2 + (1-3)^2) = \frac{1}{2} (1^2 + 4^2) = \frac{1}{2} \cdot 17 = \frac{17}{2};$
- $\Delta(\{G\}, \{H\}) = \frac{1 \cdot 1}{1+1} \|M_{GH} - M_{GGH}\|^2 =$   
 $= \frac{1}{2} \left\| \begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 3 \\ 2 \end{pmatrix} \right\|^2 = \frac{1}{2} \left\| \begin{pmatrix} 2 \\ 3 \end{pmatrix} - \begin{pmatrix} 3 \\ 2 \end{pmatrix} \right\|^2 =$   
 $= \frac{1}{2} ((2-3)^2 + (3-2)^2) = \frac{1}{2} (1^2 + 1^2) = \frac{1}{2} \cdot 2 = 1;$
- $\Delta(\{H\}, \{I\}) = \Delta(\{G\}, \{I\}) = \Delta(\{E\}, \{F\}) = 2;$
- $\Delta(\{I\}, \{H\}) = \Delta(\{G\}, \{I\}) = \Delta(\{E\}, \{F\}) = 2;$   

↳ distanță minimă este  $\frac{1}{2}$   $\Rightarrow C_1 = \overline{\{A, B\}}$ ;
- $\Delta(\{I\}, \{J\}) = \frac{1}{2} \left\| \begin{pmatrix} -4 \\ -2 \end{pmatrix} + \begin{pmatrix} -3 \\ -2 \end{pmatrix} \right\|^2 = \frac{1}{2} \cdot \begin{pmatrix} -7 \\ -4 \end{pmatrix} = \begin{pmatrix} -3.5 \\ -2 \end{pmatrix};$
- $M_{C_1} = \frac{1}{2} \left( \begin{pmatrix} -4 \\ -2 \end{pmatrix} + \begin{pmatrix} -3 \\ -2 \end{pmatrix} \right) = \frac{1}{2} \left( \begin{pmatrix} -7 \\ -4 \end{pmatrix} \right) =$
- $\Delta(C_1, C) = \frac{2 \cdot 1}{2+1} \|M_{C_1} - M_{CC}\|^2 =$   
 $= \frac{2}{3} \left\| \begin{pmatrix} -1.5 \\ -2 \end{pmatrix} - \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\|^2 = \frac{2}{3} \left\| \begin{pmatrix} -1.5 \\ -2 \end{pmatrix} \right\|^2 =$   
 $= \frac{2}{3} \left( 1.5^2 + 2^2 \right) = \frac{2}{3} \cdot 2.25 = \frac{4.5}{3} = 1.5 > \frac{1}{2} = 0.5 \Rightarrow$
- $\Delta(C_1, C_2) = \Delta(C_1, D) \quad (\frac{4.5}{3} = 1.5 > \frac{1}{2} = 0.5) \Rightarrow$   

↳  $\Delta(C_1, C_2)$  >  $\Delta(C_1, D)$  este  $\frac{1}{2}$   $\Rightarrow C_2 = \overline{\{C, D\}}$ ;
- $M_{C_2} = \frac{1}{2} \left( \begin{pmatrix} -2 \\ -2 \end{pmatrix} + \begin{pmatrix} -1 \\ -2 \end{pmatrix} \right) = \frac{1}{2} \cdot \begin{pmatrix} -3 \\ -4 \end{pmatrix} = \begin{pmatrix} -1.5 \\ -2 \end{pmatrix};$
- $\Delta(C_1, C_2) = \frac{2 \cdot 2}{2+2} \|M_{C_1} - M_{C_2}\|^2 = \frac{4}{4} \left\| \begin{pmatrix} -1.5 \\ -2 \end{pmatrix} - \begin{pmatrix} -1.5 \\ -2 \end{pmatrix} \right\|^2 =$   
 $= 1 \cdot \left\| \begin{pmatrix} 0 \\ 0 \end{pmatrix} \right\|^2 = 1^2 + 0^2 = 0;$
- $\Delta(C_2, E) = \frac{2 \cdot 1}{2+1} \|M_{C_2} - M_E\|^2 = \frac{2}{3} \left\| \begin{pmatrix} -1.5 \\ -2 \end{pmatrix} - \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\|^2 =$   
 $= \frac{2}{3} \left\| \begin{pmatrix} -1.5 \\ -2 \end{pmatrix} \right\|^2 = \frac{2}{3} (1.5^2 + 2^2) = \frac{2}{3} \cdot 7.25 = 4.8(3);$



- $\mu_{C6} = \frac{1}{2} \left( \begin{pmatrix} 3,5 \\ 3,5 \end{pmatrix} + \begin{pmatrix} 2,5 \\ 2,5 \end{pmatrix} \right) = \frac{1}{2} \begin{pmatrix} 6 \\ 6 \end{pmatrix} = \begin{pmatrix} 3 \\ 3 \end{pmatrix};$
- $D(C_5, C_6) = \frac{2 \cdot 4}{2+4} \|\mu_{C5} - \mu_{C6}\|^2 = \frac{8}{6} \left\| \begin{pmatrix} 1 \\ 0 \end{pmatrix} - \begin{pmatrix} 3 \\ 3 \end{pmatrix} \right\|^2 =$   
 $= \frac{4}{3} \left\| \begin{pmatrix} -2 \\ -3 \end{pmatrix} \right\|^2 = \frac{4}{3} (2^2 + 3^2) = \frac{4}{3} \cdot 13 = 17, (3);$   
 $\hookrightarrow 17, (3) \Rightarrow \text{distanta minimă este } 4 \Rightarrow$   
 $C_7 = \{A, B, C, D\};$
- $\mu_{C7} = \frac{1}{2} \left( \begin{pmatrix} -3,5 \\ -2 \end{pmatrix} + \begin{pmatrix} -1,5 \\ -2 \end{pmatrix} \right) = \frac{1}{2} \begin{pmatrix} -5 \\ -4 \end{pmatrix} = \begin{pmatrix} -2,5 \\ -2 \end{pmatrix};$
- $D(C_7, C_5) = \frac{2 \cdot 4}{2+4} \|\mu_{C7} - \mu_{C5}\|^2 = \frac{8}{6} \left\| \begin{pmatrix} -2,5 \\ -2 \end{pmatrix} - \begin{pmatrix} 1 \\ 0 \end{pmatrix} \right\|^2 =$   
 $= \frac{4}{3} \left\| \begin{pmatrix} -3,5 \\ -2 \end{pmatrix} \right\|^2 = \frac{4}{3} (3,5^2 + 2^2) = \frac{4}{3} \cdot 16,25 = 21, (6);$   
 $\hookrightarrow 17, (3) < 21, (6) \Rightarrow \text{distanta minimă este}$   
 $C_8 = \{E, F, G, H, I, J\};$   
 $\hookrightarrow C_9 = \{A, B, C, D, E, F, G, H, I, J\};$

### Ex. 8

- $\tilde{r}_1(1,30, 0,87), \tilde{r}_2(1,76, 0,84), \tilde{r}_3(2,32, 1,63), \tilde{r}_4(2,31, 2,09);$   
 $\tilde{r}_5(1,44, 2,11), \tilde{r}_6(5,02, 3,02), \tilde{r}_7(5,74, 3,84), \tilde{r}_8(2,25, 3,47);$
- $\tilde{r}_9(4,71, 3,60), \tilde{r}_{10}(3,47, 4,96);$
- X-means; 2 cluster;  $\mu_1(6) = \tilde{r}_1, \mu_2(6) = \tilde{r}_{10};$
- primă iteratie;
- a)  $d(\tilde{r}_2, \tilde{r}_1) = \sqrt{(1,76-1,30)^2 + (0,84-0,87)^2} =$   
 $= \sqrt{0,14^2 + 0,13^2} = \sqrt{0,0365} = 0,19;$
- $d(\tilde{r}_2, \tilde{r}_{10}) = \sqrt{(1,76-3,47)^2 + (0,84-4,96)^2} =$   
 $= \sqrt{1,41^2 + 4,12^2} = \sqrt{18,96} = 4,35;$
- $\hookrightarrow d(\tilde{r}_2, \tilde{r}_1) < d(\tilde{r}_2, \tilde{r}_{10}) \Rightarrow C_1 = \{\tilde{r}_1, \tilde{r}_2\};$

- $d(R_3, R_{10}) = \sqrt{(2,32 - 3,17)^2 + (1,63 - 4,98)^2} =$   
 $= \sqrt{0,85^2 + 3,33^2} = \sqrt{11,81} = 3,44;$
- $d(R_3, R_1) = \sqrt{(2,32 - 1,90)^2 + (1,63 - 0,97)^2} =$   
 $= \sqrt{0,42^2 + 0,66^2} = \sqrt{0,612} = 0,78;$   
 $\hookrightarrow d(R_3, R_1) < d(R_3, R_{10}) \Rightarrow C_1 = \{R_1, R_2, R_3\};$
- $d(R_4, R_1) = \sqrt{(2,31 - 1,90)^2 + (2,03 - 0,97)^2} =$   
 $= \sqrt{0,41^2 + 1,12^2} = \sqrt{1,425} = 1,19;$
- $d(R_4, R_{10}) = \sqrt{(2,31 - 3,17)^2 + (2,03 - 4,98)^2} =$   
 $= \sqrt{0,96^2 + 2,95^2} = \sqrt{8,9765} = 3,03;$   
 $\hookrightarrow d(R_4, R_1) < d(R_4, R_{10}) \Rightarrow C_1 = \{R_1, R_2, R_3, R_4\};$
- $d(R_5, R_1) = \sqrt{(1,14 - 1,90)^2 + (2,11 - 0,97)^2} =$   
 $= \sqrt{0,76^2 + 1,14^2} = \sqrt{1,877} = 1,37;$
- $d(R_5, R_{10}) = \sqrt{(1,14 - 3,17)^2 + (2,11 - 4,98)^2} =$   
 $= \sqrt{2,03^2 + 2,85^2} = \sqrt{12,2434} = 3,49;$   
 $\hookrightarrow d(R_5, R_1) < d(R_5, R_{10}) \Rightarrow C_1 = C_1 \cup \{R_5\};$
- $d(R_6, R_1) = \sqrt{(5,02 - 1,90)^2 + (3,02 - 0,97)^2} =$   
 $= \sqrt{3,12^2 + 2,05^2} = \sqrt{13,9369} = 3,73;$
- $d(R_6, R_{10}) = \sqrt{(5,02 - 3,17)^2 + (3,02 - 4,98)^2} =$   
 $= \sqrt{1,85^2 + 1,94^2} = 2,68;$   
 $\hookrightarrow d(R_6, R_{10}) < d(R_6, R_1) \Rightarrow C_2 = C_2 \cup \{R_{10}\};$
- $d(R_7, R_1) = \sqrt{(5,74 - 1,90)^2 + (3,84 - 0,97)^2} =$   
 $= \sqrt{3,84^2 + 2,87^2} = 4,43;$
- $d(R_7, R_{10}) = \sqrt{(5,74 - 3,17)^2 + (3,84 - 4,98)^2} =$   
 $= \sqrt{2,57^2 + 1,12^2} = 2,80;$

(19)

$$\hookrightarrow d(\tilde{r}_7, \tilde{r}_{10}) < d(\tilde{r}_7, \tilde{r}_1) \Rightarrow c_2 = c_2 \vee \{ \tilde{r}_7 \};$$

$$\bullet d(\tilde{r}_8, \tilde{r}_1) = \sqrt{(2,25 - 1,90)^2 + (3,47 - 0,97)^2} = \sqrt{0,35^2 + 2,5^2} = 2,55;$$

$$\bullet d(\tilde{r}_8, \tilde{r}_{10}) = \sqrt{(2,25 - 3,17)^2 + (3,47 - 4,36)^2} = \sqrt{0,92^2 + 1,45^2} = 1,75;$$

$$\bullet d(\tilde{r}_8, \tilde{r}_{10}) < d(\tilde{r}_8, \tilde{r}_1) \Rightarrow c_2 = c_2 \vee \{ \tilde{r}_8 \};$$

$$\bullet d(\tilde{r}_9, \tilde{r}_1) = \sqrt{(4,71 - 1,90)^2 + (3,60 - 0,97)^2} = \sqrt{2,81^2 + 2,63^2} = 3,85;$$

$$\bullet d(\tilde{r}_9, \tilde{r}_{10}) = \sqrt{(4,71 - 3,17)^2 + (3,60 - 4,36)^2} = \sqrt{1,54^2 + 1,36^2} = 2,05;$$

$$\hookrightarrow d(\tilde{r}_9, \tilde{r}_{10}) < d(\tilde{r}_9, \tilde{r}_1) \Rightarrow c_2 = c_2 \vee \{ \tilde{r}_9 \};$$

$$\left\{ \begin{array}{l} c_1 = \{ \tilde{r}_1, \tilde{r}_2, \tilde{r}_3, \tilde{r}_4, \tilde{r}_5 \}, \\ c_2 = \{ \tilde{r}_6, \tilde{r}_7, \tilde{r}_8, \tilde{r}_9, \tilde{r}_{10} \}, \end{array} \right.$$

b) compositio, center and K-means converge;

$$\bullet \text{compositio, center} = \frac{x_{11} + x_{21} + x_{31} + x_{41} + x_{51}}{5} =$$

$$\bullet x_{41} = \frac{1,90 + 1,76 + 2,32 + 2,31 + 1,14}{5} = 1,886;$$


$$\bullet y_{41} = \frac{4,71 + 4,72 + 4,73 + 4,74 + 4,75}{5} =$$

$$\bullet y_{41} = \frac{0,97 + 0,84 + 1,63 + 2,09 + 2,11}{5} = 1,528;$$

$$\bullet x_{42} = \frac{5,02 + 5,74 + 2,25 + 4,71 + 3,17}{5} = 4,178;$$

$$\bullet y_{42} = \frac{3,02 + 3,84 + 3,47 + 3,60 + 4,36}{5} = 3,778;$$

$$\hookrightarrow \mu_1((1,886, 1,528)); \mu_2((4,178, 3,778));$$



$\hookrightarrow \{x_i\} = \{1, 2, 3, 4, 5\} \text{ și } \{y_i\} = \{2, 1, 3, 4, 5\}$

---

ca la iteratia anteriora  $\hookrightarrow$  algoritmul converge;